Watsonx Orchestrate Chat with Agents

API REST para comunicación con IBM Watsonx Orchestrate

Índice

- Visión General
- Endpoints Disponibles
- Cómo Obtener las Credenciales
- Configuración del Proyecto
- Documentación de la API
- Variables de Entorno
- Notas Importantes

Visión General

Este asset proporciona un **servicio HTTP basado en FastAPI** que permite la comunicación con **IBM Watson Orchestrate (WxO)** a través de tres endpoints principales:

Endpoint	Descripción
`/list_agents`	Devuelve una lista de agentes disponibles en una determinada instancia de watsonx Orchestrate
`/get_response`	Devuelve una única respuesta de un agente WxO
`/stream_response`	Transmite la respuesta del agente en tiempo real usando Server-Sent Events (SSE)

Enlaces Útiles

- **Código Fuente**: GitHub Repository
- **Endpoints Implementados**: Routes Directory

Crear una Instancia de Watsonx Orchestrate

Después de iniciar sesión en **IBM Cloud**, en el campo de búsqueda escriba `watsonx Orchestrate`.

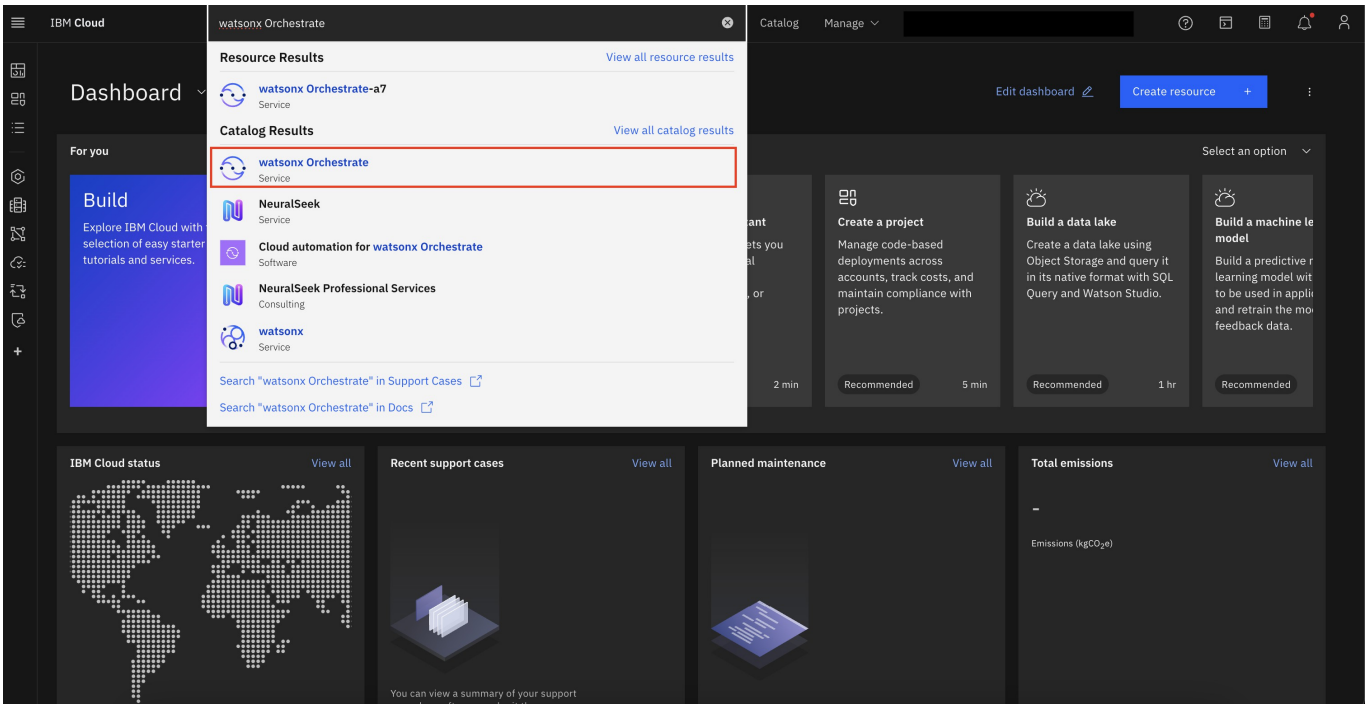

Elija la **location** de su instancia y el **plan** que mejor le convenga

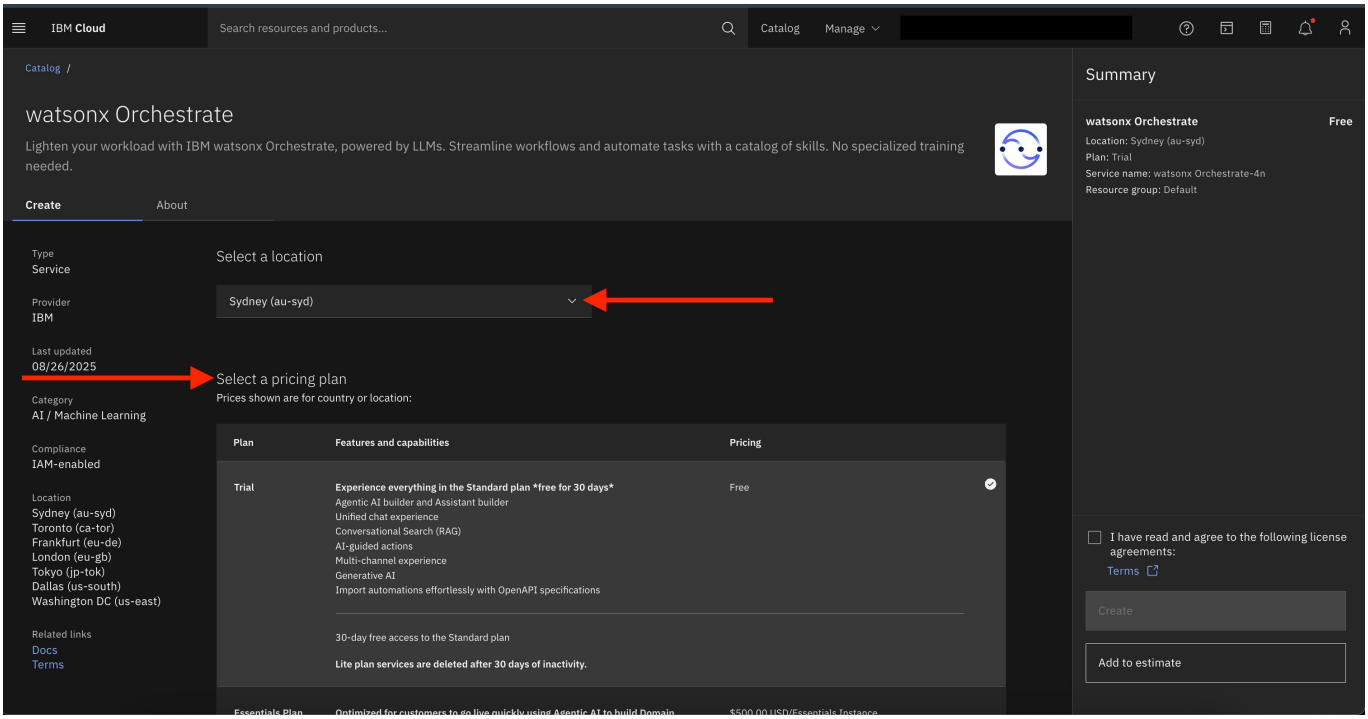

Por último, escriba el **nombre del servicio**, opcionalmente **tags** y **tags de activación**, y seleccione un **resource group**.

Acepte los términos de IBM Cloud en el lado derecho de la pantalla y haga clic en **Create**.

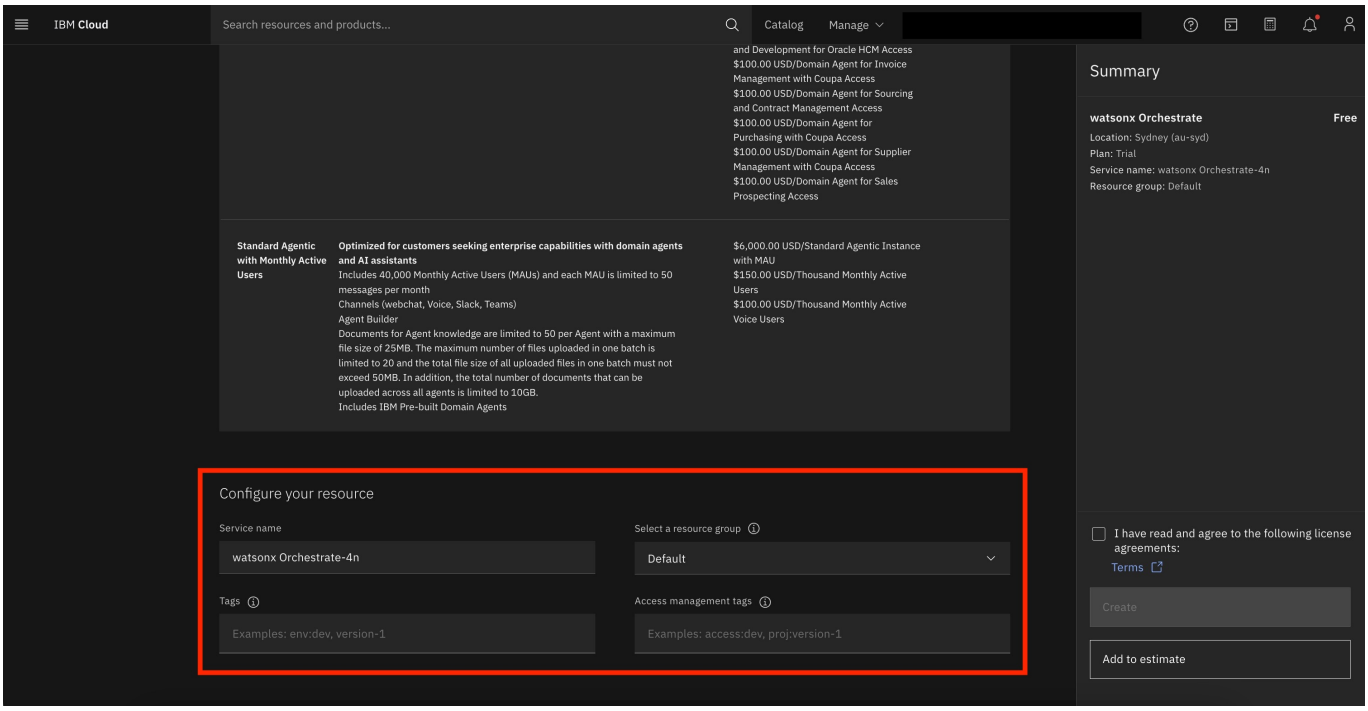

Con su instancia creada, haga clic en **Launch watsonx Orchestrate**.

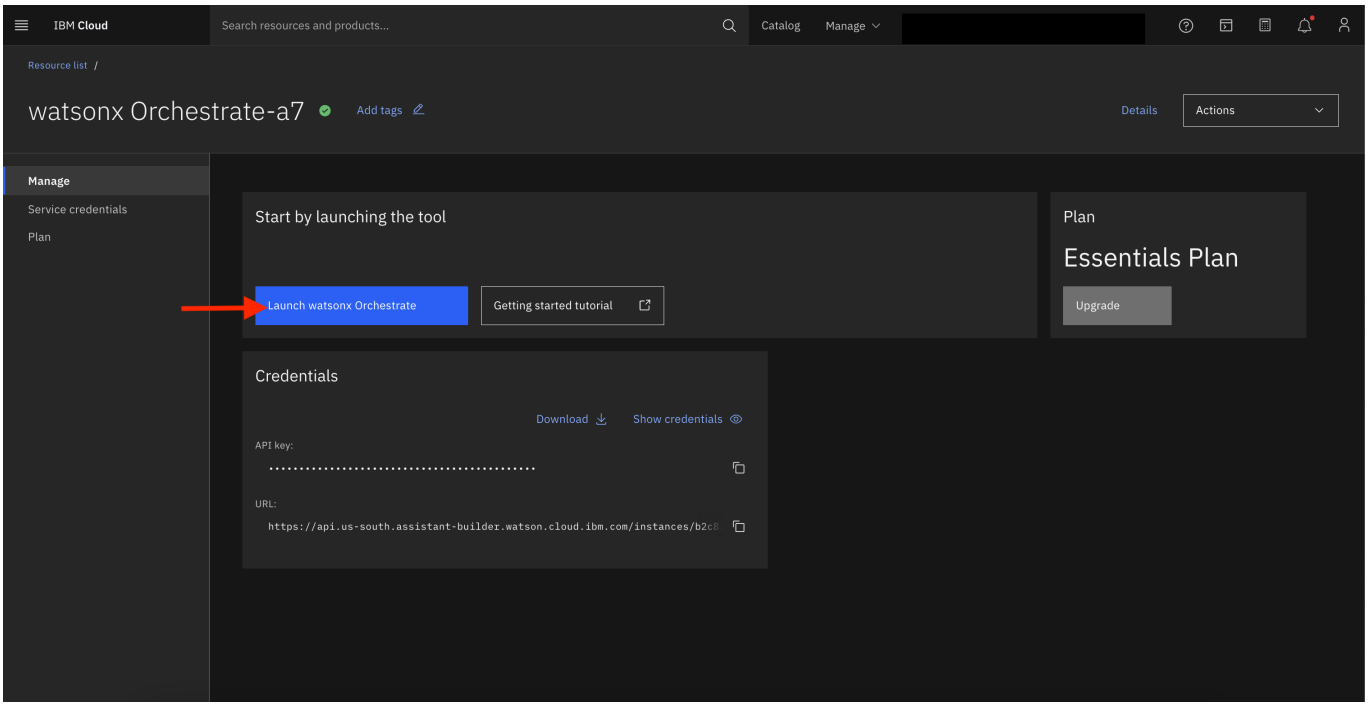

Para comunicarse con Watsonx Orchestrate vía API, necesitará obtener dos credenciales esenciales:

- `IAM_API_KEY`
- `WXO_INSTANCE_ID`

Cómo obtener las credenciales de watsonx Orchestrate

En el ícono de las iniciales de su nombre y apellido en el lado derecho de la interfaz

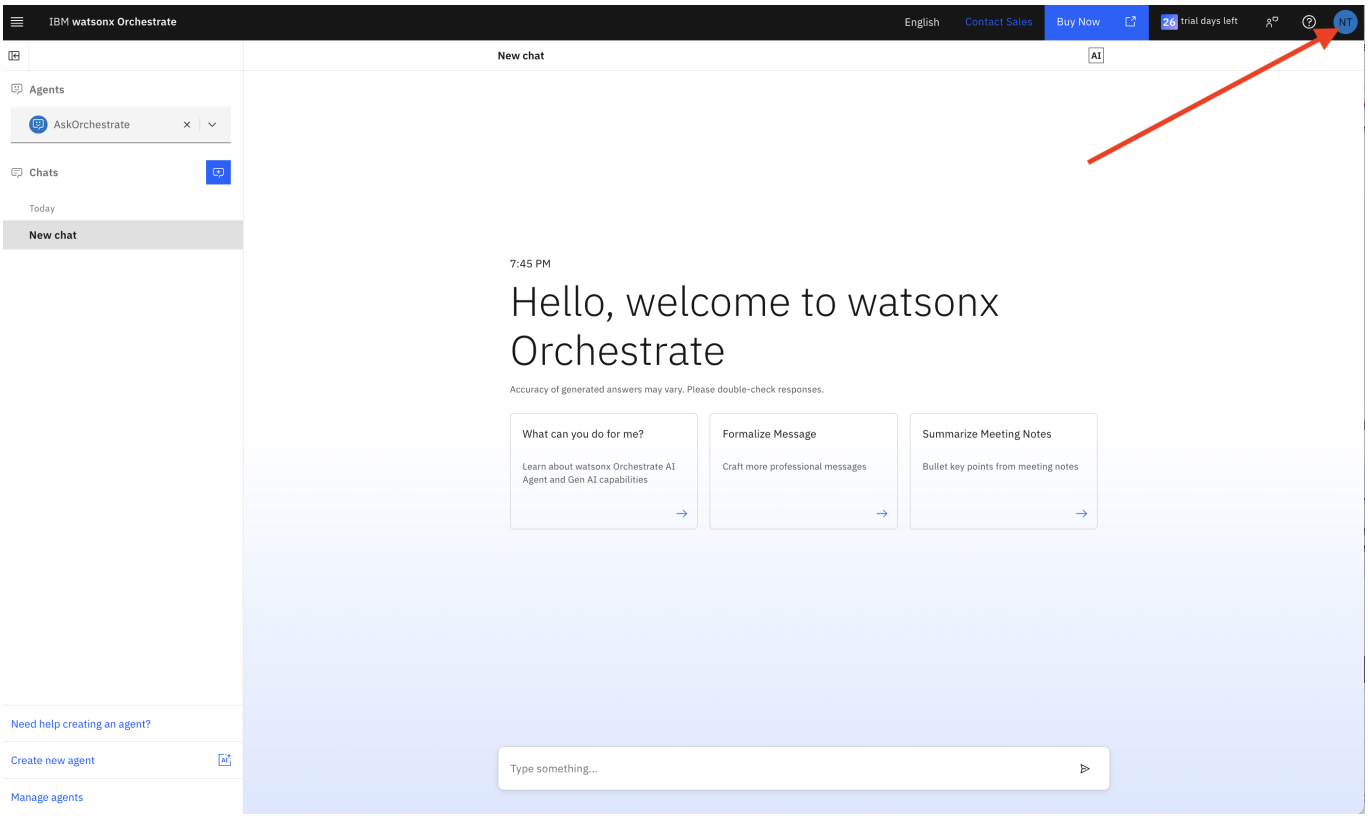

Haga clic en **Settings**.

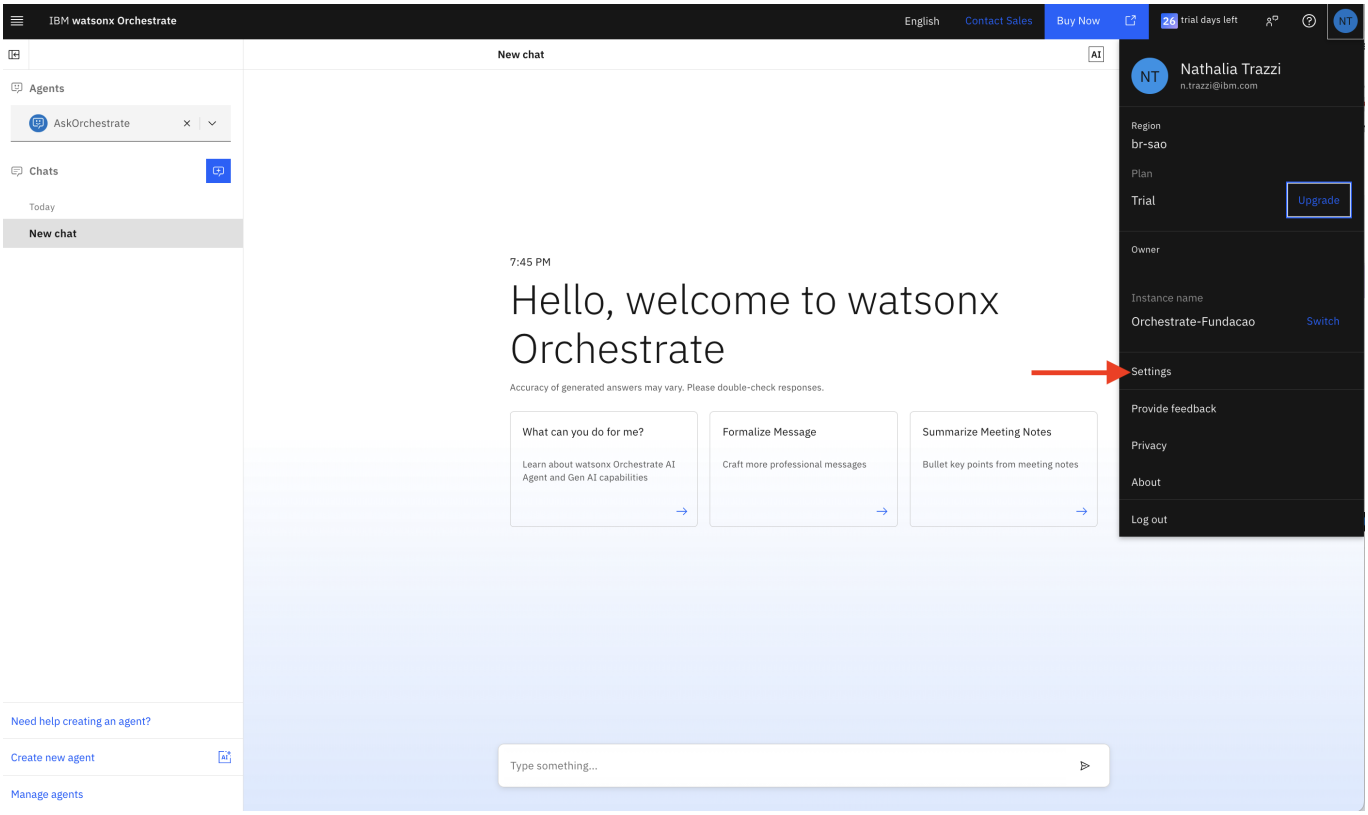

En la página de configuración entre en la pestaña **API details**

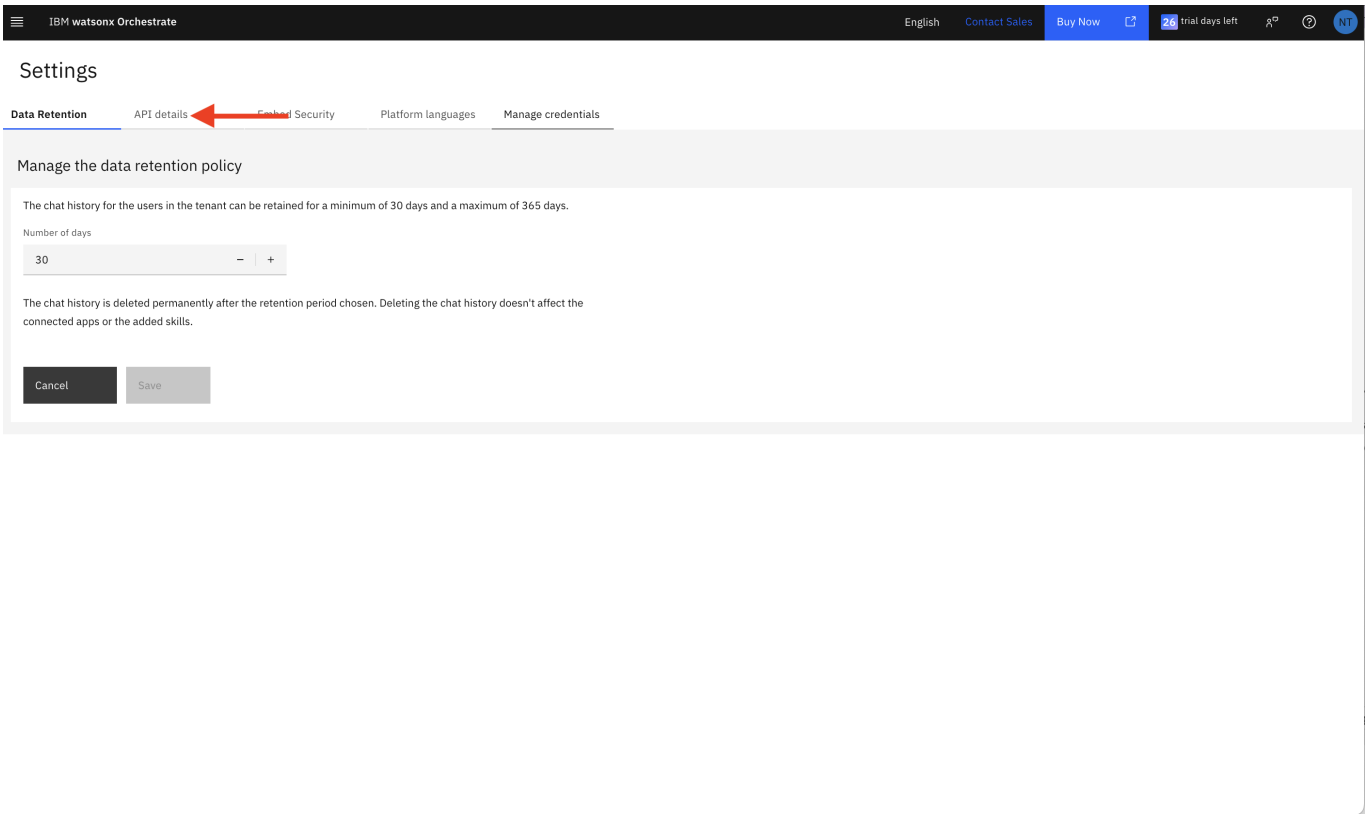

1. Copie el ID de su instancia

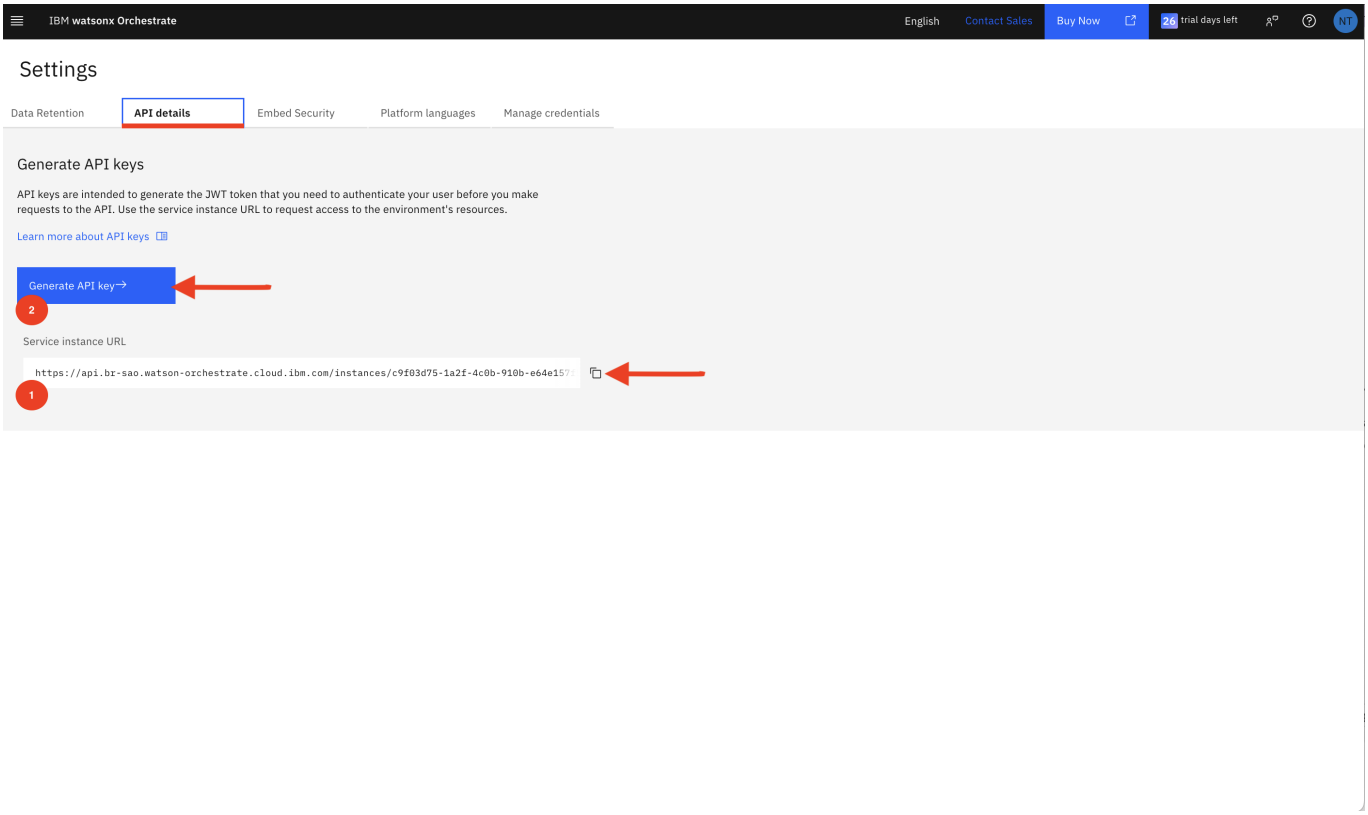

2. A continuación, haga clic en `Generate API Key`

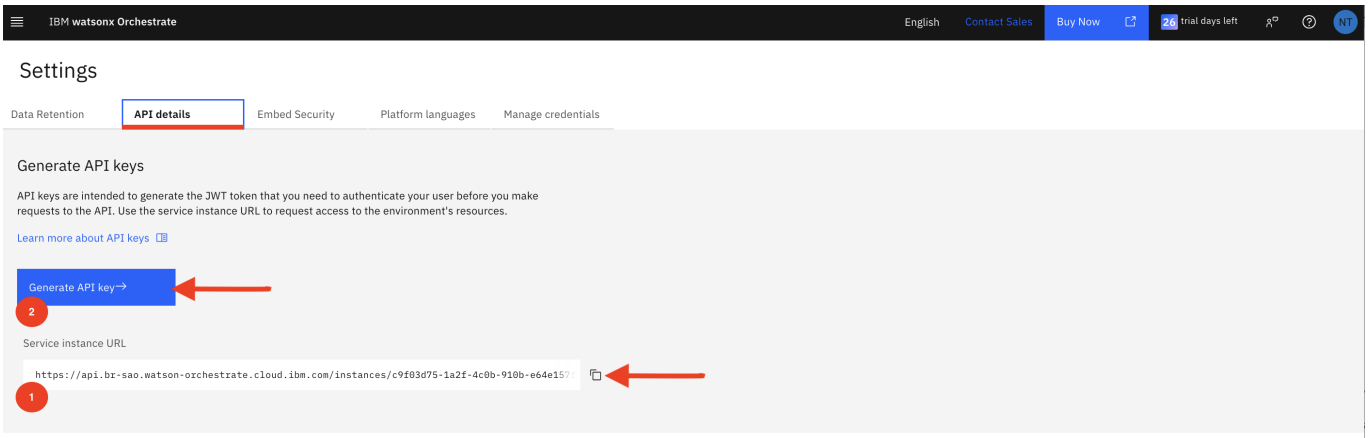

En la siguiente página, haga clic en **Generate API key**.

Será redirigido al catálogo donde crea, visualiza y trabaja con claves de API de IBM Cloud.

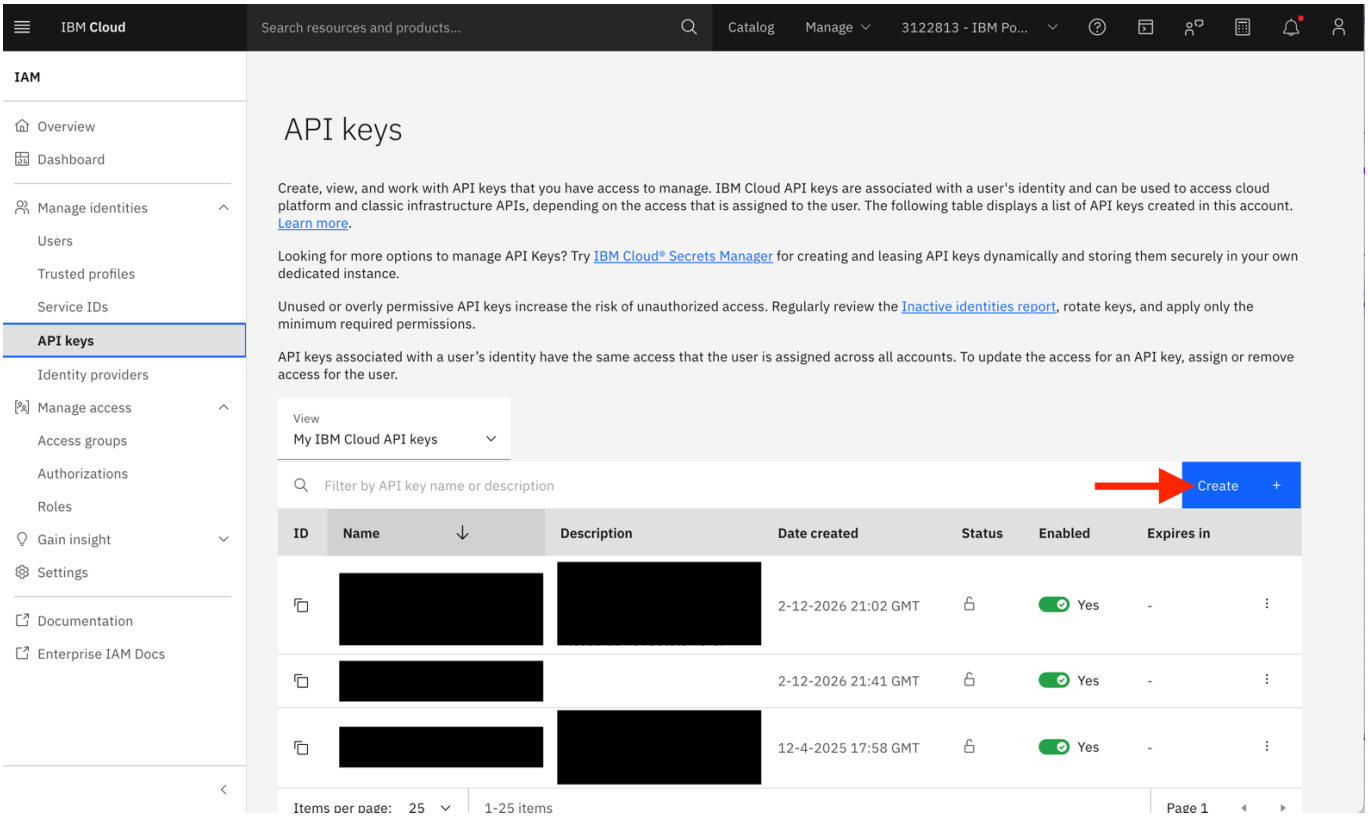

> **¿Qué es una API Key?**
>
> Una API Key es un secreto que permite que usuarios, aplicaciones o servicios accedan a IBM Cloud de forma autenticada. Funciona como una "contraseña técnica" usada en CLIs, automatizaciones, pipelines o integraciones.

Configuración de la API Key

Name (Nombre)

Dé un nombre descriptivo a la clave, como:

- `apikey-wxo`
- `local-development-key`

> **Consejo**: Use nombres que indiquen el propósito, responsable o entorno.

Description (Opcional)

Aquí puede agregar una descripción de su clave, ayudando en su identificación.

Lead Action (Acción en Caso de Filtración)

Opción	Descripción
🔘 **Disable the leaked key** (recomendado)	La clave se desactiva automáticamente. Buena opción para producción.
🔘 **Delete the leaked key**	La clave se elimina permanentemente.
🔘 **Nothing**	No se toma ninguna acción. No recomendado.

API Key Expiration (Expiración)

Puede elegir si la clave debe expirar automáticamente.

Opción	Descripción
🔘 **Set expiration**	Permite elegir una fecha futura. -> Ideal para accesos temporales, integraciones de corto plazo, etc. Cuando expire, la clave se deshabilitará automáticamente.
🔘 **Sin expiración** (default)	La clave no expira.

Session Management (Gestión de Sesión)

Define si esta clave puede ser usada para gestión de sesiones en IBM Cloud CLI.

Opción	Descripción
🔘 **Yes**	Permite que la clave sea usada para iniciar sesión en CLI con `ibmcloud login --apikey`
🔘 **No**	La API Key no podrá ser usada para iniciar sesión en sesiones CLI. Use cuando desee restringir la clave solo para llamadas específicas de API.

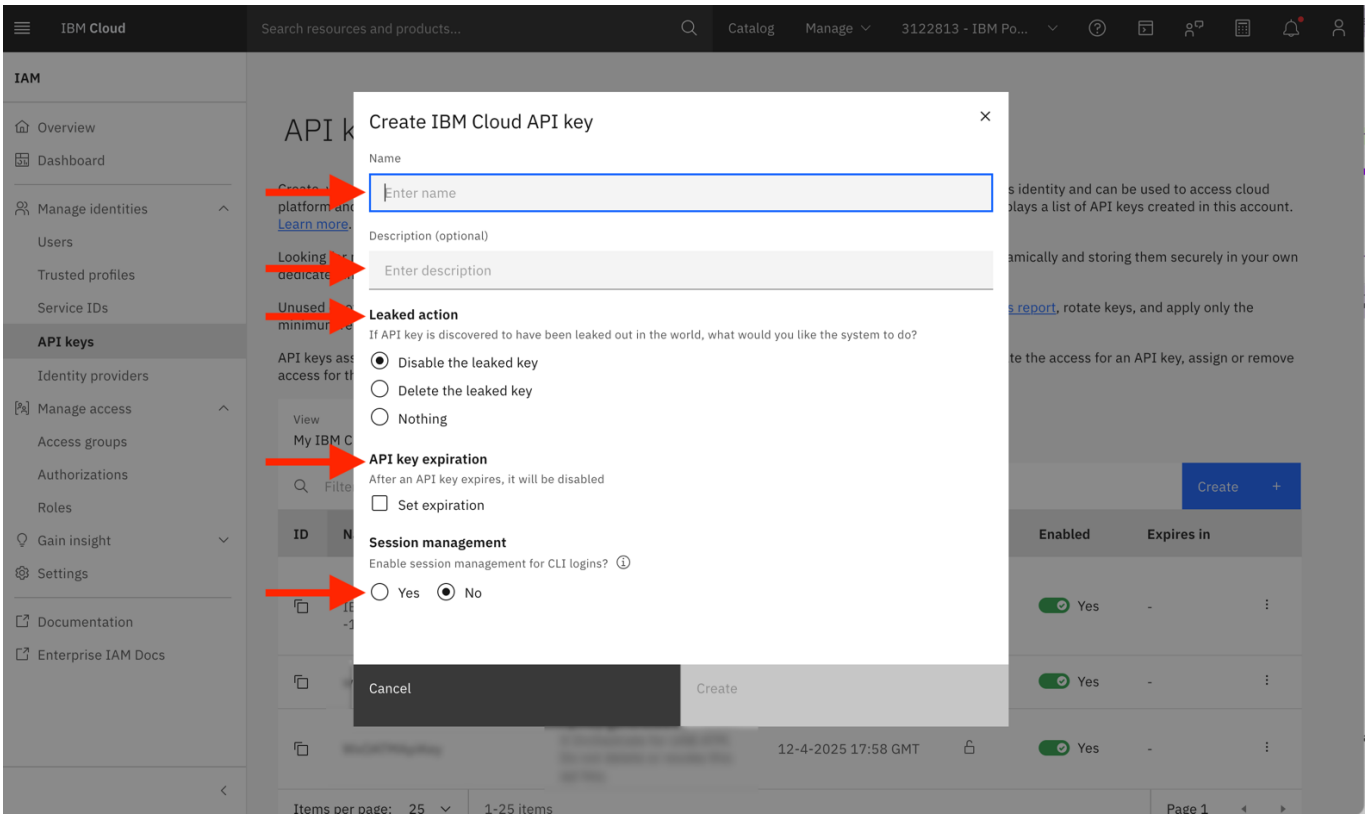

Después de completar todo, haga clic en **Create**.

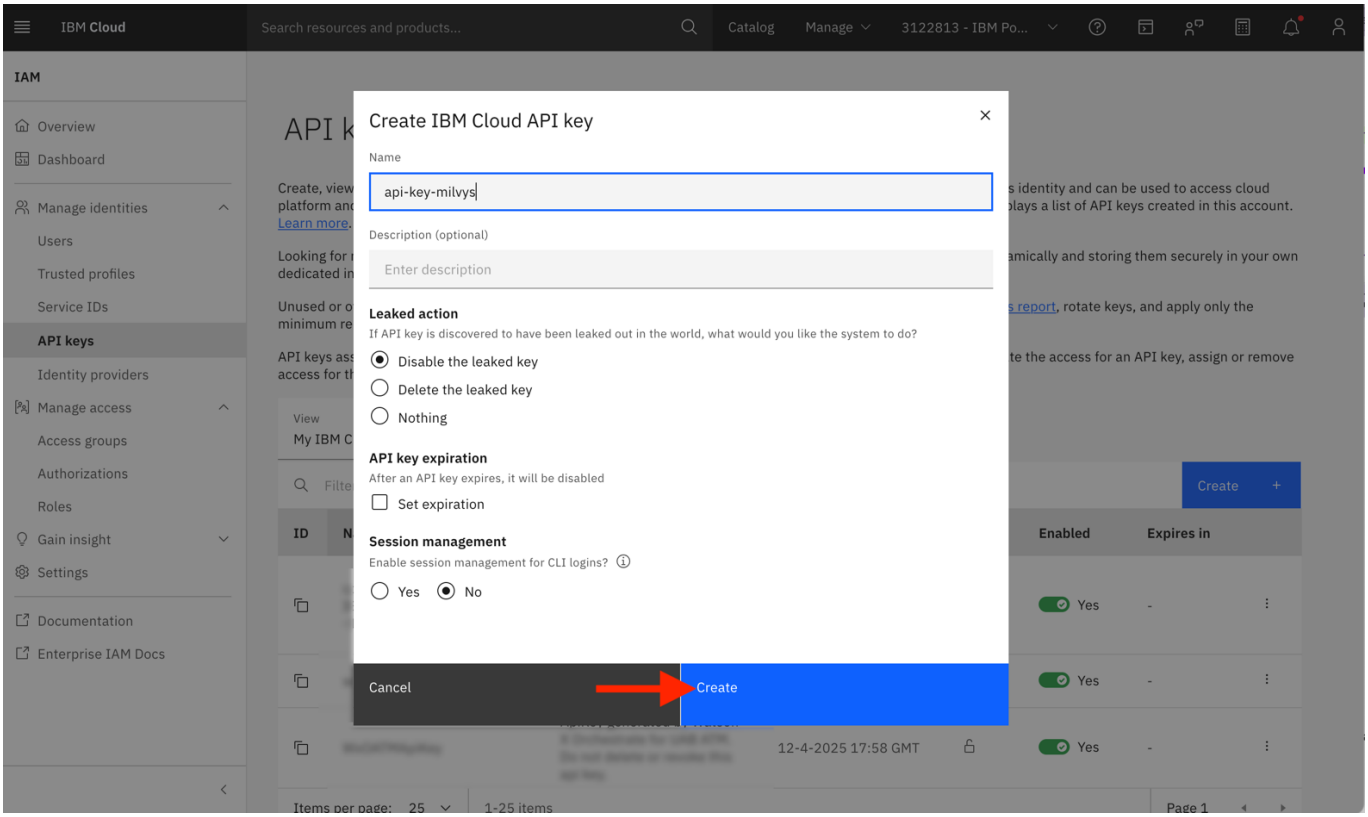

> **IMPORTANTE**: Aproveche este momento para copiar o descargar su API Key. La clave estará disponible por algunos segundos. Después de este período, no será posible visualizarla nuevamente.

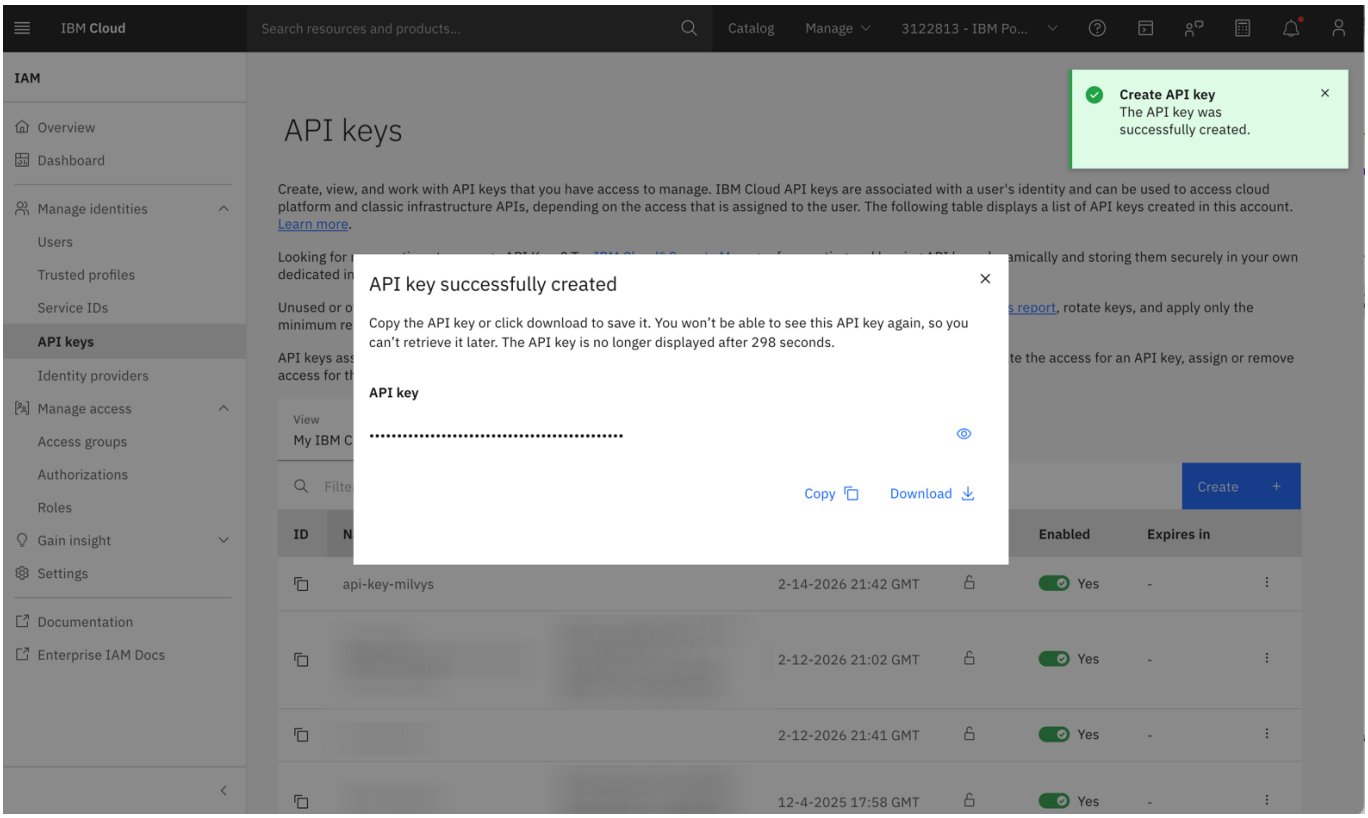

Después de obtener las credenciales, ya posee las dos informaciones necesarias para la ejecución de la interacción vía backend con el chat de su agente (watsonx Orchestrate).

1. **Navegue hasta el directorio del proyecto**:

```
cd ./source/rest_api/
```

2. **Configure las variables de entorno**:

   - Cambie el nombre del archivo `.env_example` a `.env`
   - Complete con sus credenciales:

```
IAM_API_KEY=su-api-key-aqui
WXO_INSTANCE_ID=su-instance-id-aqui
```

3. **Instale las dependencias**:

```
pip install -r requirements.txt
```

4. **Ejecute el servidor**:

```
python app.py
```

Gestión de Conversaciones (Thread ID)

> **Importante**: Para mantener el contexto de la conversación entre múltiples mensajes:

- **Primer mensaje**: Haga su primera llamada a `/get_response` o `/stream_response` **sin proporcionar** un `thread_id` (déjelo vacío u omítalo de la solicitud). La respuesta incluirá un valor `thread_id`.
- **Mensajes subsiguientes**: Para continuar la conversación en el mismo contexto, incluya el `thread_id` devuelto como parámetro en todas las solicitudes subsiguientes.

Esto permite que el agente mantenga el contexto entre los mensajes.

`POST /get_response`

Envía un mensaje a un agente y recibe una respuesta única.

Solicitud (parámetros de query):

```
POST /get_response?message=Hello&agent_id=your-agent-
id[&thread_id=optional-thread-id]
```

Parámetros:

- `message` (obligatorio): El mensaje a ser enviado
- `agent_id` (obligatorio): ID del agente
- `thread_id` (opcional): ID del thread para continuar una conversación

Observaciones:

- Para el primer mensaje, **no incluya** `thread_id`
- Para mensajes siguientes, defina `thread_id` con el valor devuelto en la respuesta anterior

Respuesta:

```
{
  "response": "Agent response here",
  "thread_id": "thread-id-value"
}
```

`POST /stream_response`

Envía un mensaje a un agente WxO y recibe la respuesta de forma continua (SSE).

Solicitud (parámetros de query):

```
POST /stream_response?message=Hello&agent_id=your-agent-id[&thread_id=optional-thread-id]
```

Parámetros:

- `message` (obligatorio): El mensaje a ser enviado
- `agent_id` (obligatorio): ID del agente
- `thread_id` (opcional): ID del thread para continuar una conversación

Observaciones:

- Para el primer mensaje, **no incluya** `thread_id`
- Para mensajes siguientes, defina `thread_id` con el valor devuelto en la respuesta anterior

Respuesta:

```
Content-Type: text/event-stream

data: {"chunk": "Response", "thread_id": "thread-id-value"}

data: {"chunk": " chunk", "thread_id": "thread-id-value"}

data: {"chunk": " here", "thread_id": "thread-id-value"}
```

Cada bloque de datos del evento se envía en tiempo real conforme el agente procesa la respuesta.

Variables de Entorno

Variable	Descripción
`IAM_API_KEY`	Clave de API de IBM Cloud IAM
`WXO_INSTANCE_ID`	ID de la instancia de Watsonx Orchestrate

Notas Importantes

> **Atención**:
>
> - Asegúrese de que su **ID del agente** sea válido
> - Su **clave IAM** debe tener permisos suficientes para acceder a la instancia
> - El endpoint `/stream_response` usa **streaming (SSE)** para interactuar con el agente watsonx Orchestrate procesando respuestas en tiempo real

---

Ahora está listo para integrar su aplicación con IBM Watson Orchestrate.

Desarrollado por Nathalia Trazzi