Watsonx Orchestrate Chat with Agents

API REST pour la communication avec IBM Watsonx Orchestrate

IBM CLOUD POWERED | FASTAPI FRAMEWORK | PYTHON 3.8+

Sommaire

- Vue d'ensemble
- Endpoints Disponibles
- Comment Obtenir les Identifiants
- Configuration du Projet
- Documentation de l'API
- Variables d'Environnement
- Notes Importantes

Vue d'ensemble

Cet asset fournit un **service HTTP basé sur FastAPI** qui permet la communication avec **IBM Watson Orchestrate (WxO)** via trois endpoints principaux :

Endpoint	Description
`/list_agents`	Retourne une liste d'agents disponibles dans une instance donnée de watsonx Orchestrate
`/get_response`	Retourne une réponse unique d'un agent WxO
`/stream_response`	Transmet la réponse de l'agent en temps réel en utilisant Server-Sent Events (SSE)

Liens Utiles

- **Code Source** : GitHub Repository
- **Endpoints Implémentés** : Routes Directory

Créer une Instance de Watsonx Orchestrate

Après vous être connecté à **IBM Cloud**, dans le champ de recherche, tapez `watsonx Orchestrate`.

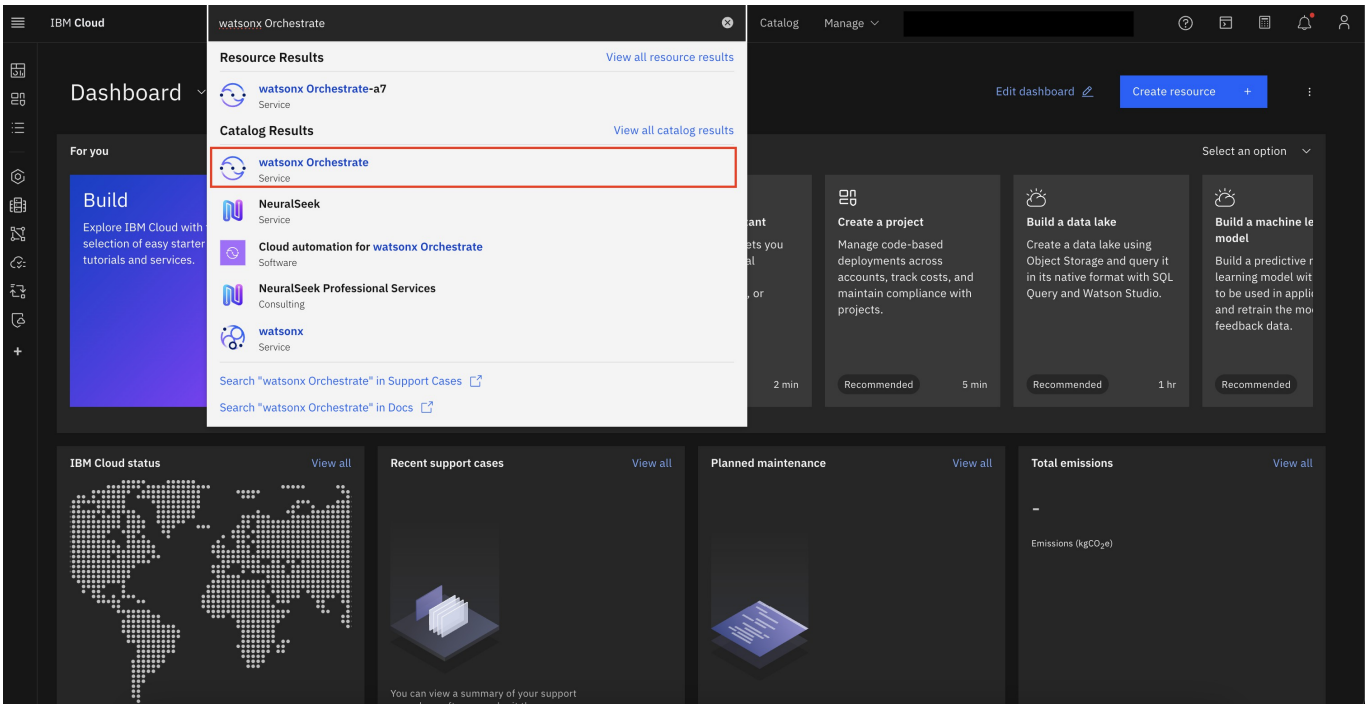

Choisissez la **location** de votre instance et le **plan** qui vous convient le mieux

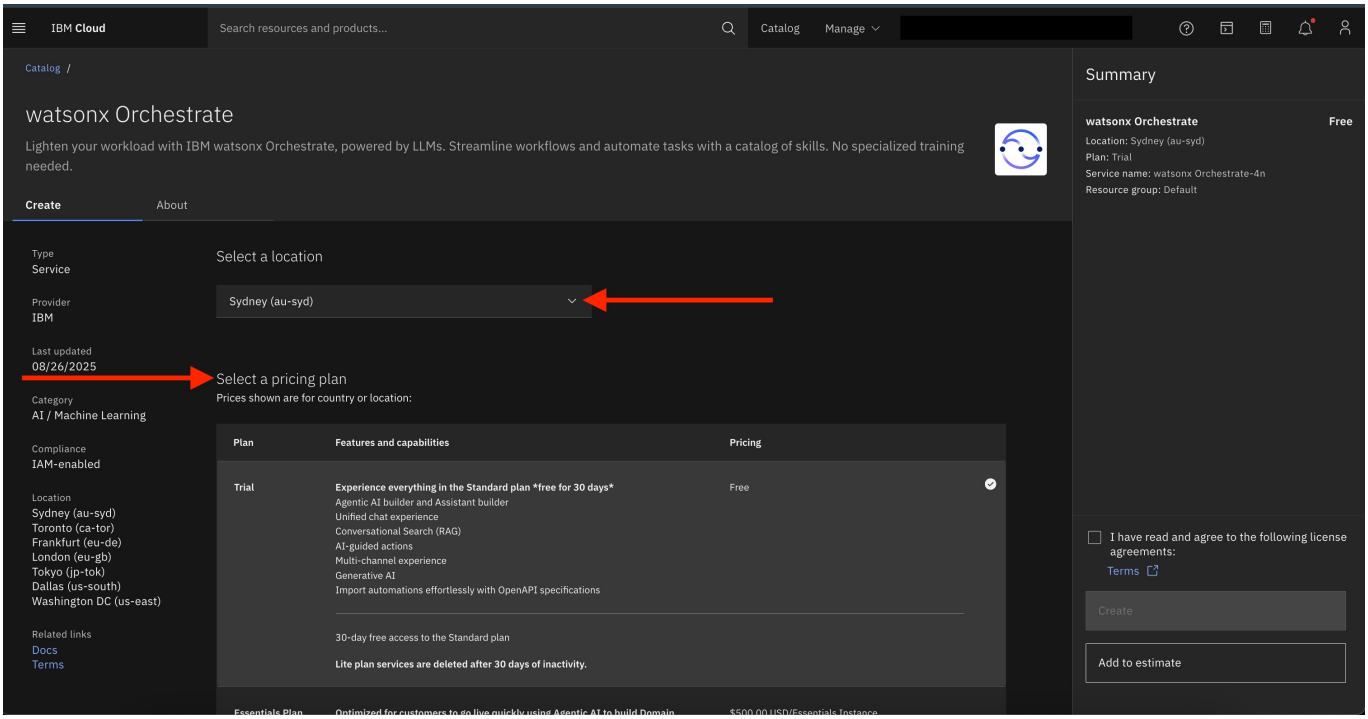

Enfin, saisissez le **nom du service**, optionnellement des **tags** et des **tags de déclenchement**, et sélectionnez un **resource group**.

Acceptez les conditions d'IBM Cloud sur le côté droit de l'écran et cliquez sur **Create**.

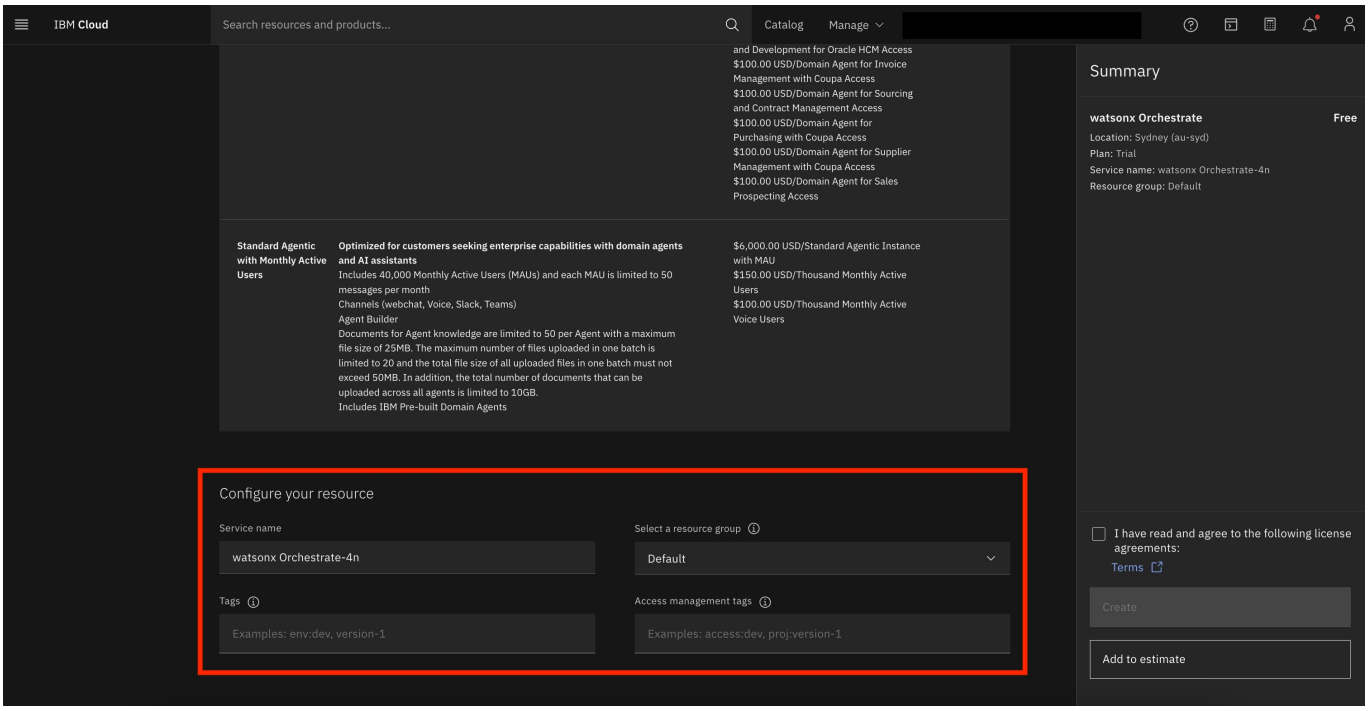

Avec votre instance créée, cliquez sur **Launch watsonx Orchestrate**.

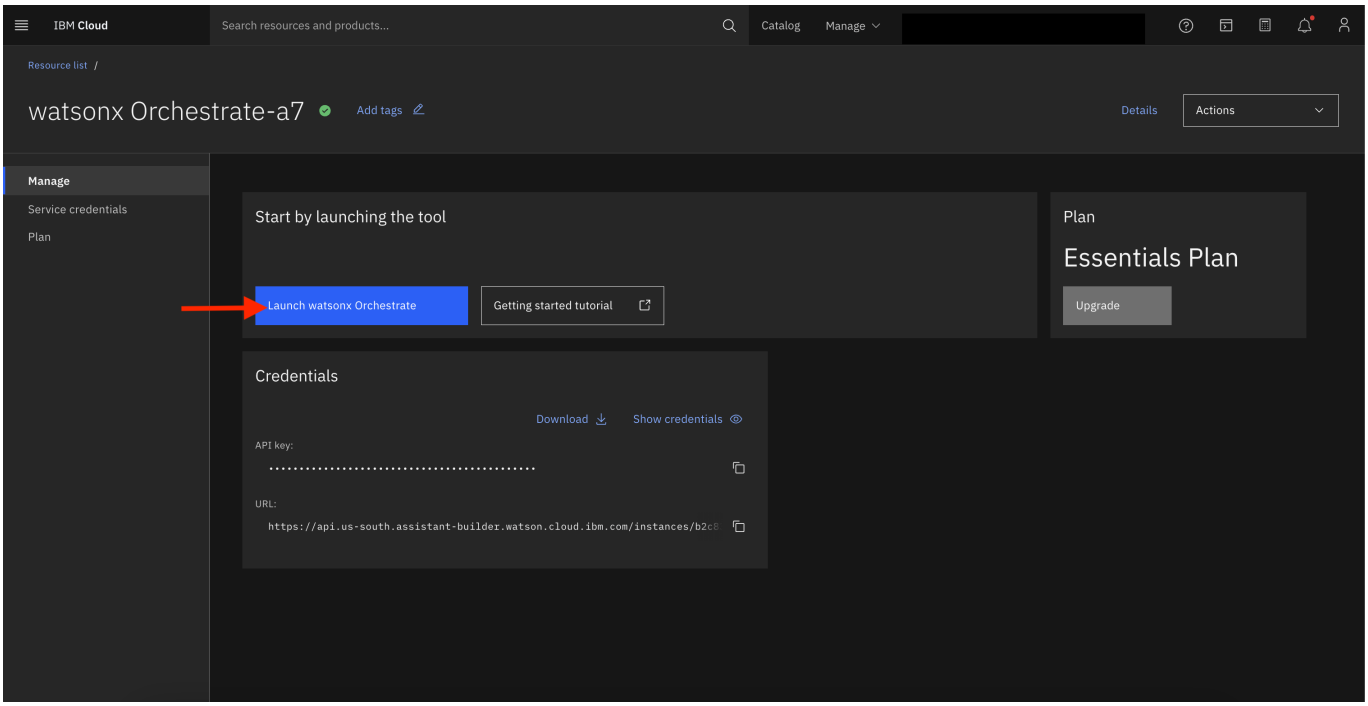

Pour communiquer avec Watsonx Orchestrate via l'API, vous devrez obtenir deux identifiants essentiels :

- `IAM_API_KEY`
- `WXO_INSTANCE_ID`

Comment obtenir les identifiants de watsonx Orchestrate

Dans l'icône des initiales de votre nom et prénom sur le côté droit de l'interface

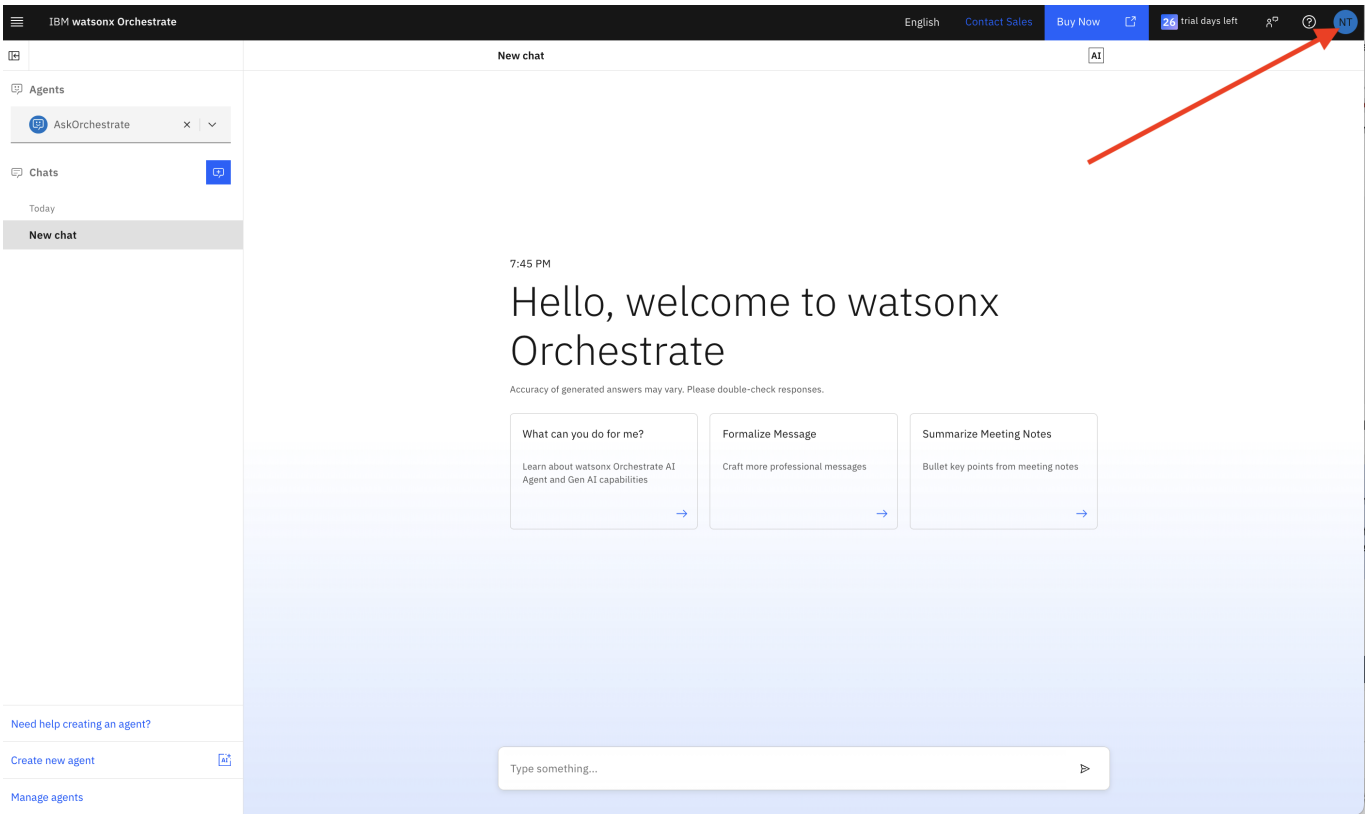

Cliquez sur **Settings**.

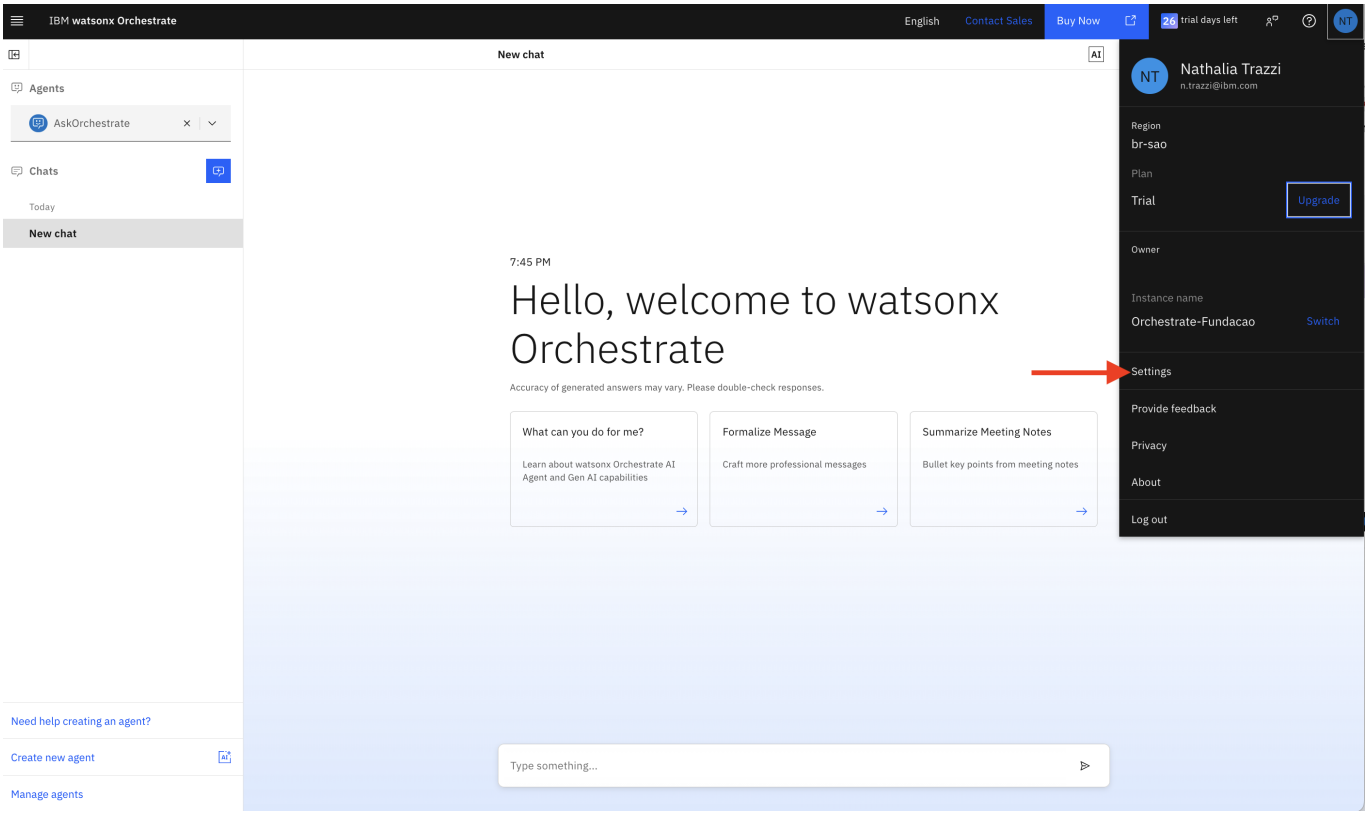

Dans la page de configuration, accédez à l'onglet **API details**

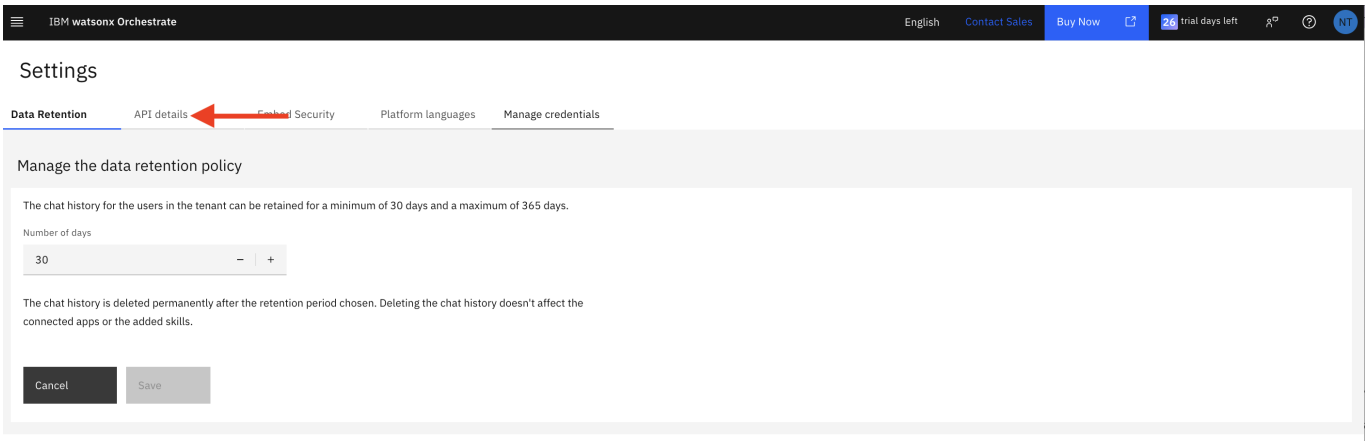

1. Copiez l'ID de votre instance

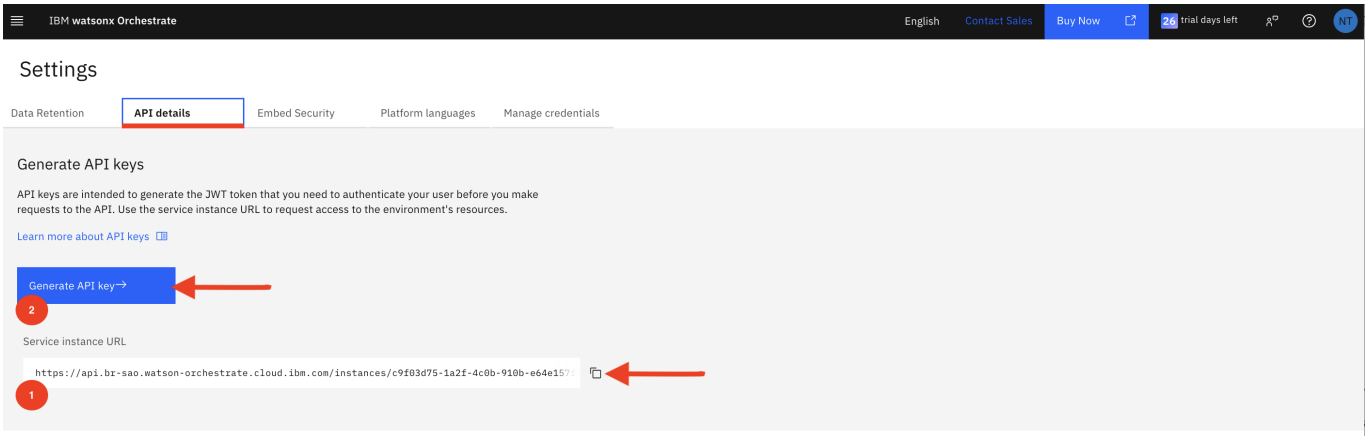

2. Ensuite, cliquez sur `Generate API Key`

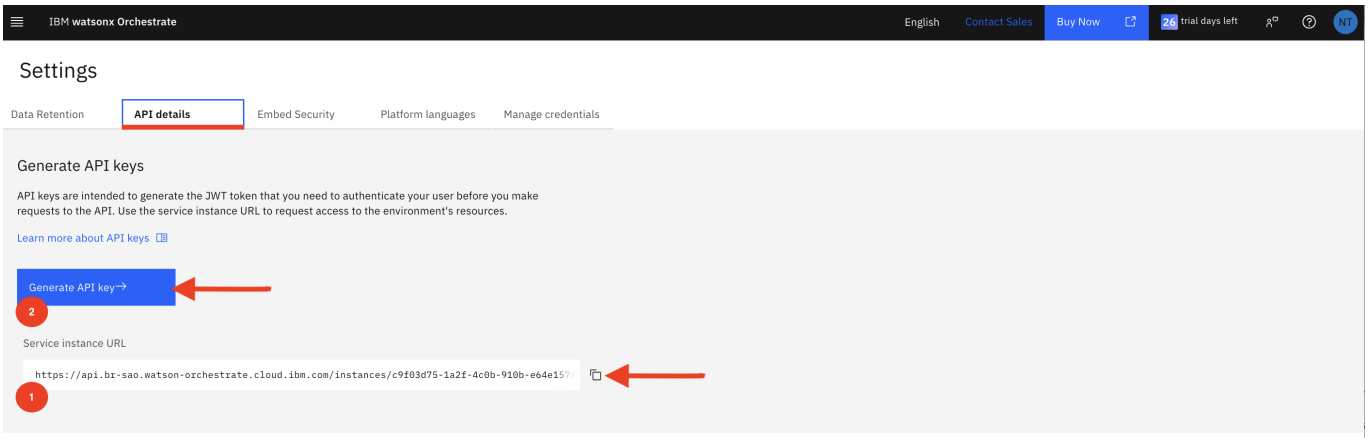

Sur la page suivante, cliquez sur **Generate API key**.

Vous serez redirigé vers le catalogue où vous créez, visualisez et travaillez avec les clés API d'IBM Cloud.

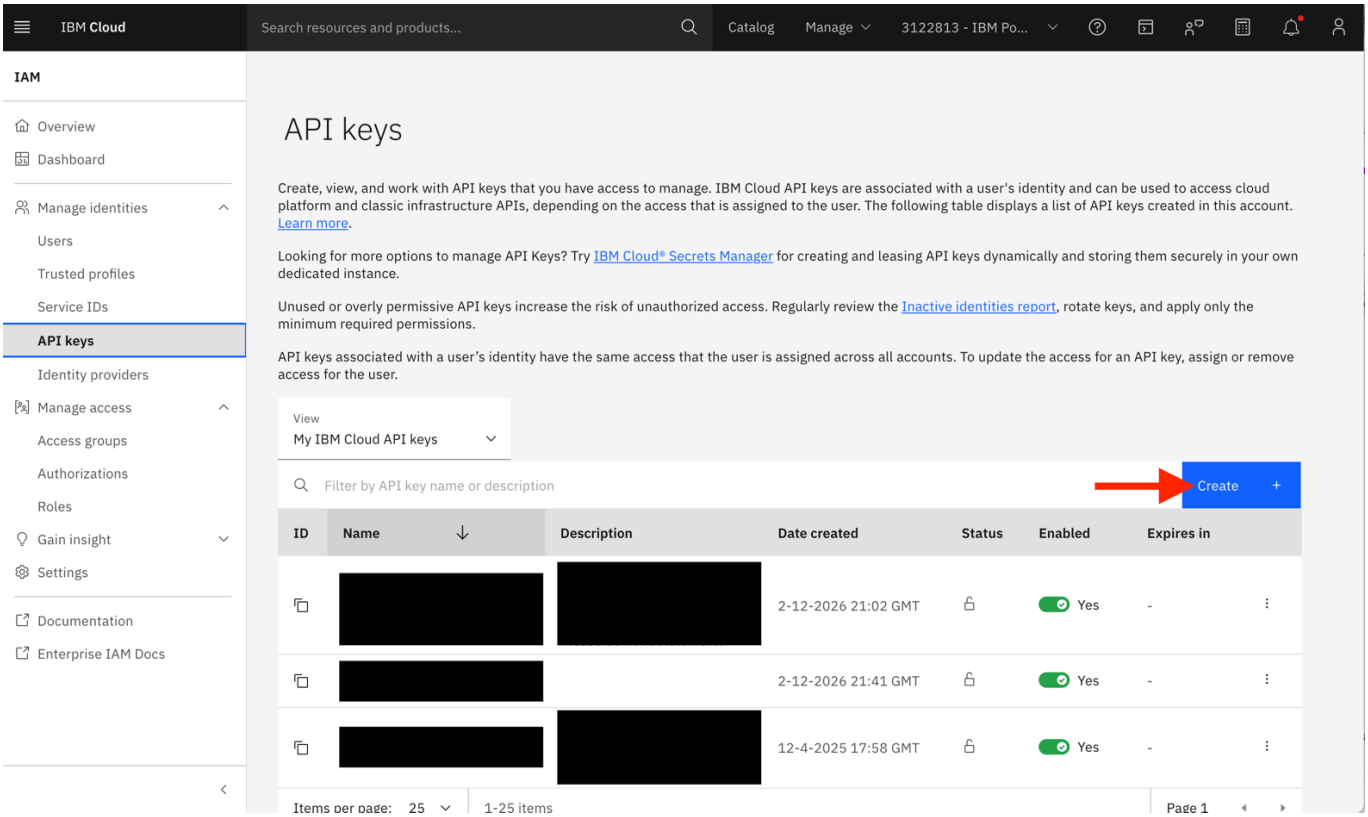

> **Qu'est-ce qu'une API Key ?**
>
> Une API Key est un secret qui permet aux utilisateurs, applications ou services d'accéder à IBM Cloud de manière authentifiée. Elle fonctionne comme un "mot de passe technique" utilisé dans les CLIs, automatisations, pipelines ou intégrations.

Configuration de l'API Key

Name (Nom)

Donnez un nom descriptif à la clé, comme :

- `apikey-wxo`
- `local-development-key`

> **Conseil** : Utilisez des noms qui indiquent l'objectif, le responsable ou l'environnement.

Description (Optionnel)

Ici, vous pouvez ajouter une description de votre clé, aidant à son identification.

Lead Action (Action en Cas de Fuite)

Option	Description
🔘 **Disable the leaked key** (recommandé)	La clé est automatiquement désactivée. Bonne option pour la production.
🔘 **Delete the leaked key**	La clé est supprimée définitivement.
🔘 **Nothing**	Aucune action n'est prise. Non recommandé.

API Key Expiration (Expiration)

Vous pouvez choisir si la clé doit expirer automatiquement.

Option	Description
🔘 **Set expiration**	Permet de choisir une date future. -> Idéal pour les accès temporaires, intégrations à court terme, etc. Lorsqu'elle expire, la clé est automatiquement désactivée.
🔘 **Sans expiration** (par défaut)	La clé n'expire pas.

Session Management (Gestion de Session)

Définit si cette clé peut être utilisée pour la gestion de sessions dans IBM Cloud CLI.

Option	Description
🔘 **Yes**	Permet d'utiliser la clé pour se connecter au CLI avec `ibmcloud login --apikey`
🔘 **No**	L'API Key ne pourra pas être utilisée pour se connecter aux sessions CLI. Utilisez cette option lorsque vous souhaitez restreindre la clé uniquement aux appels API spécifiques.

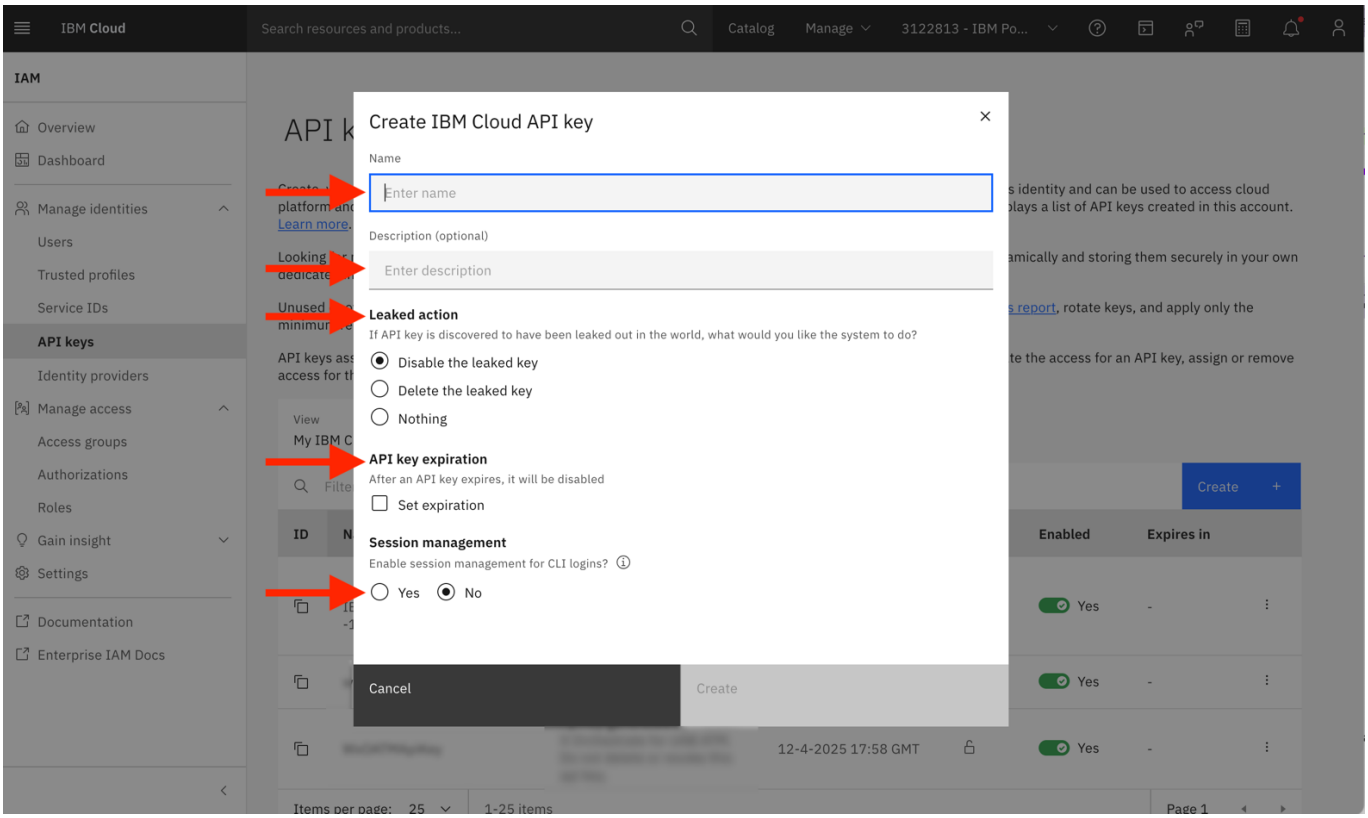

Après avoir tout rempli, cliquez sur **Create**.

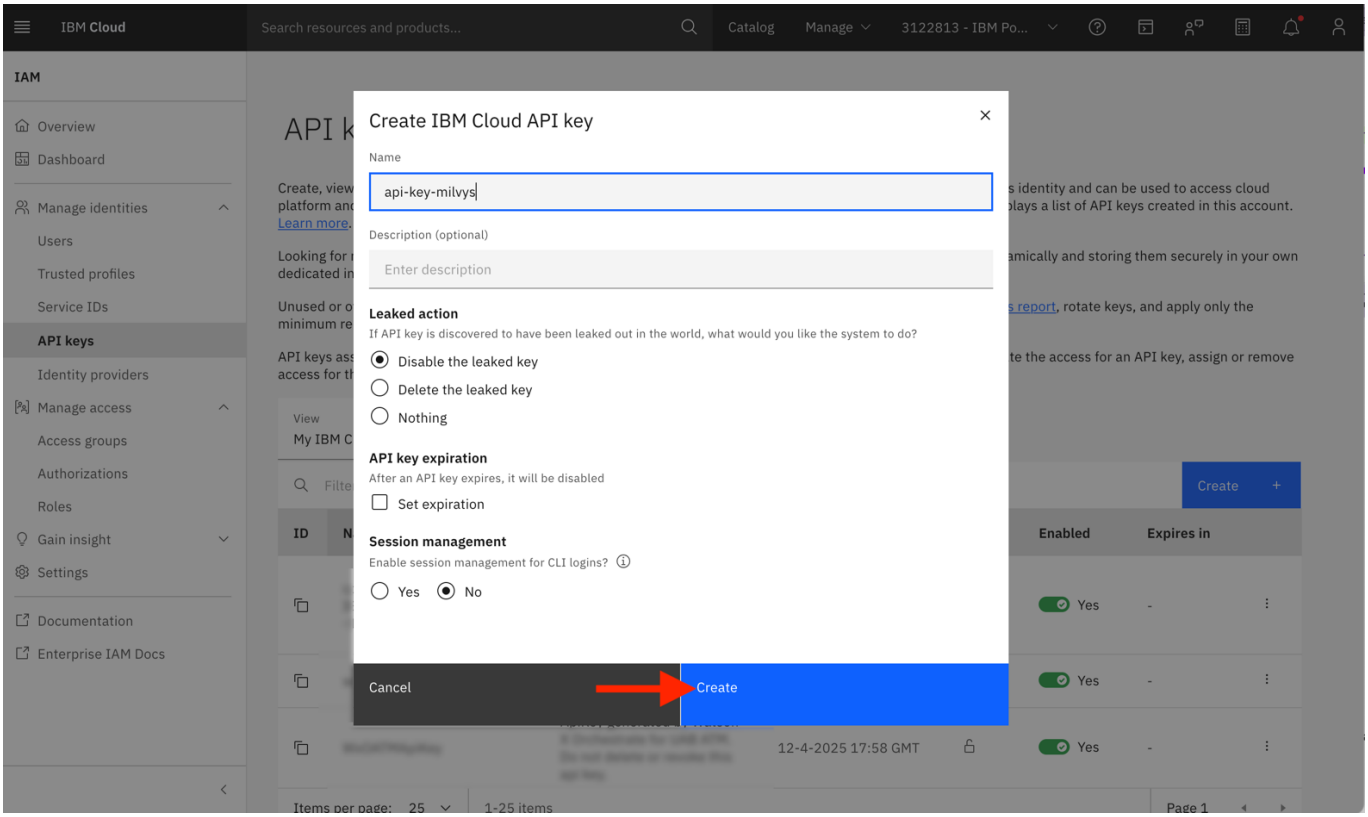

> **IMPORTANT** : Profitez de ce moment pour copier ou télécharger votre API Key. La clé sera disponible pendant quelques secondes. Après cette période, il ne sera plus possible de la visualiser à nouveau.

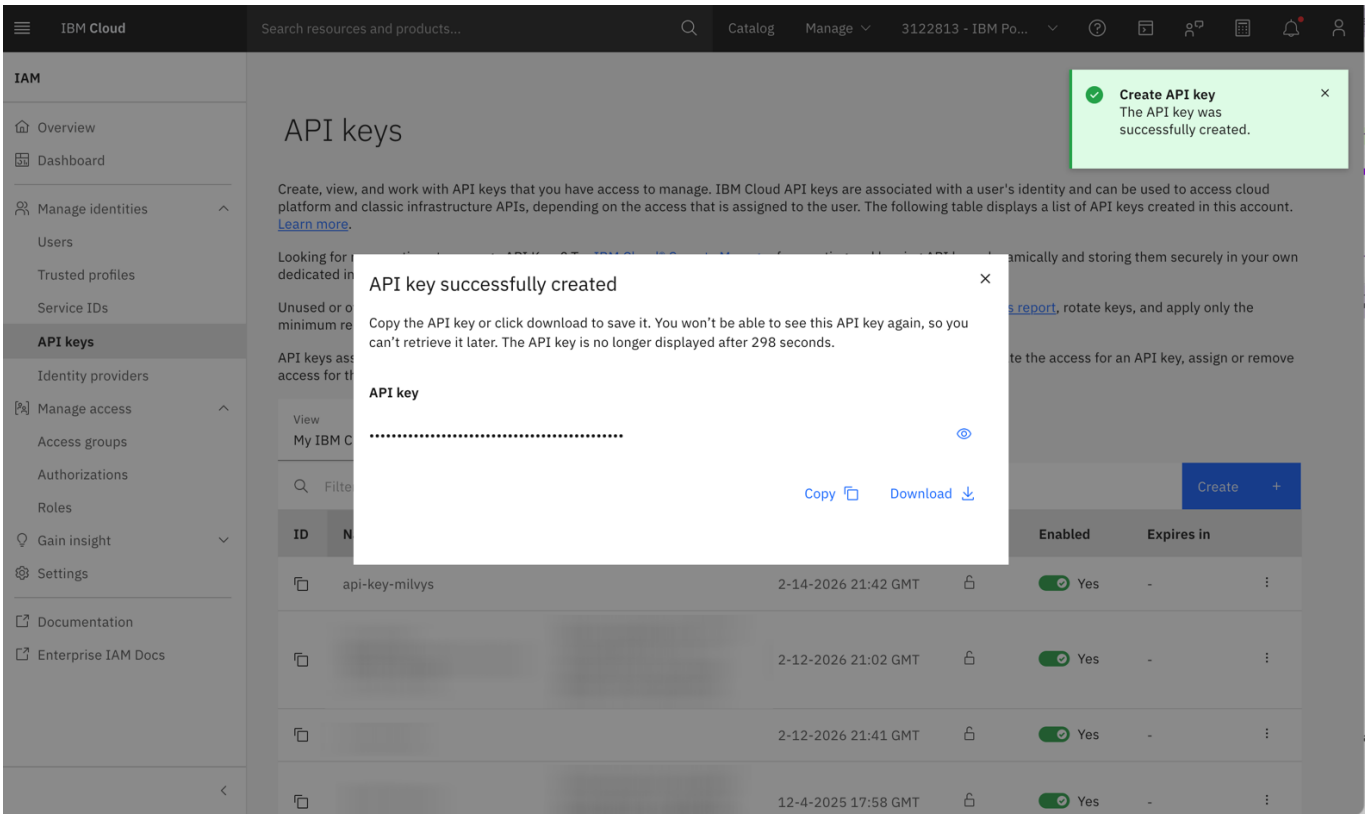

Après avoir obtenu les identifiants, vous disposez des deux informations nécessaires pour l'exécution de l'interaction via backend avec le chat de votre agent (watsonx Orchestrate).

1. **Naviguez vers le répertoire du projet** :

```
cd ./source/rest_api/
```

2. **Configurez les variables d'environnement** :

   - Renommez le fichier `.env_example` en `.env`
   - Remplissez avec vos identifiants :

```
IAM_API_KEY=votre-api-key-ici
WXO_INSTANCE_ID=votre-instance-id-ici
```

3. **Installez les dépendances** :

```
pip install -r requirements.txt
```

4. **Exécutez le serveur** :

```
python app.py
```

Gestion des Conversations (Thread ID)

> **Important** : Pour maintenir le contexte de la conversation entre plusieurs messages :

- **Premier message** : Effectuez votre premier appel à `/get_response` ou `/stream_response` **sans fournir** de `thread_id` (laissez vide ou omettez de la requête). La réponse inclura une valeur `thread_id`.
- **Messages suivants** : Pour continuer la conversation dans le même contexte, incluez le `thread_id` retourné comme paramètre dans toutes les requêtes suivantes.

Cela permet à l'agent de maintenir le contexte entre les messages.

`POST /get_response`

Envoie un message à un agent et reçoit une réponse unique.

Requête (paramètres de query) :

```
POST /get_response?message=Hello&agent_id=your-agent-
id[&thread_id=optional-thread-id]
```

Paramètres :

- `message` (obligatoire) : Le message à envoyer
- `agent_id` (obligatoire) : ID de l'agent
- `thread_id` (optionnel) : ID du thread pour continuer une conversation

Observations :

- Pour le premier message, **n'incluez pas** `thread_id`
- Pour les messages suivants, définissez `thread_id` avec la valeur retournée dans la réponse précédente

Réponse :

```
{
  "response": "Agent response here",
  "thread_id": "thread-id-value"
}
```

`POST /stream_response`

Envoie un message à un agent WxO et reçoit la réponse de manière continue (SSE).

Requête (paramètres de query) :

```
POST /stream_response?message=Hello&agent_id=your-agent-id[&thread_id=optional-thread-id]
```

Paramètres :

- `message` (obligatoire) : Le message à envoyer
- `agent_id` (obligatoire) : ID de l'agent
- `thread_id` (optionnel) : ID du thread pour continuer une conversation

Observations :

- Pour le premier message, **n'incluez pas** `thread_id`
- Pour les messages suivants, définissez `thread_id` avec la valeur retournée dans la réponse précédente

Réponse :

```
Content-Type: text/event-stream

data: {"chunk": "Response", "thread_id": "thread-id-value"}

data: {"chunk": " chunk", "thread_id": "thread-id-value"}

data: {"chunk": " here", "thread_id": "thread-id-value"}
```

Chaque bloc de données de l'événement est envoyé en temps réel au fur et à mesure que l'agent traite la réponse.

Variables d'Environnement

Variable	Description
`IAM_API_KEY`	Clé API d'IBM Cloud IAM
`WXO_INSTANCE_ID`	ID de l'instance de Watsonx Orchestrate

Notes Importantes

> **Attention** :
>
> - Assurez-vous que votre **ID d'agent** est valide
> - Votre **clé IAM** doit avoir des permissions suffisantes pour accéder à l'instance
> - L'endpoint `/stream_response` utilise le **streaming (SSE)** pour interagir avec l'agent watsonx Orchestrate en traitant les réponses en temps réel

---

Vous êtes maintenant prêt à intégrer votre application avec IBM Watson Orchestrate.

Développé par Nathalia Trazzi