Watsonx Orchestrate Chat with Agents

API REST para comunicação com IBM Watsonx Orchestrate

IBM CLOUD POWERED | FASTAPI FRAMEWORK | PYTHON 3.8+

Indice

- Visão Geral
- Endpoints Disponíveis
- Como Obter as Credenciais
- Configuração do Projeto
- Documentação da API
- Variáveis de Ambiente
- Notas Importantes

Visão Geral

Este asset fornece um **serviço HTTP baseado em FastAPI** que permite a comunicação com o **IBM Watson Orchestrate (WxO)** por meio de três endpoints principais:

Endpoint	Descrição
`/list_agents`	Retorna uma lista de agentes disponíveis em uma determinada instância de watsonx Orchestrate
`/get_response`	Retorna uma única resposta de um agente WxO
`/stream_response`	Transmite a resposta do agente em tempo real usando Server-Sent Events (SSE)

Links Úteis

- **Código Fonte**: GitHub Repository
- **Endpoints Implementados**: Routes Directory

Criar uma Instância do Watsonx Orchestrate

Após fazer login na **IBM Cloud**, no campo de pesquisa digite `watsonx Orchestrate`.

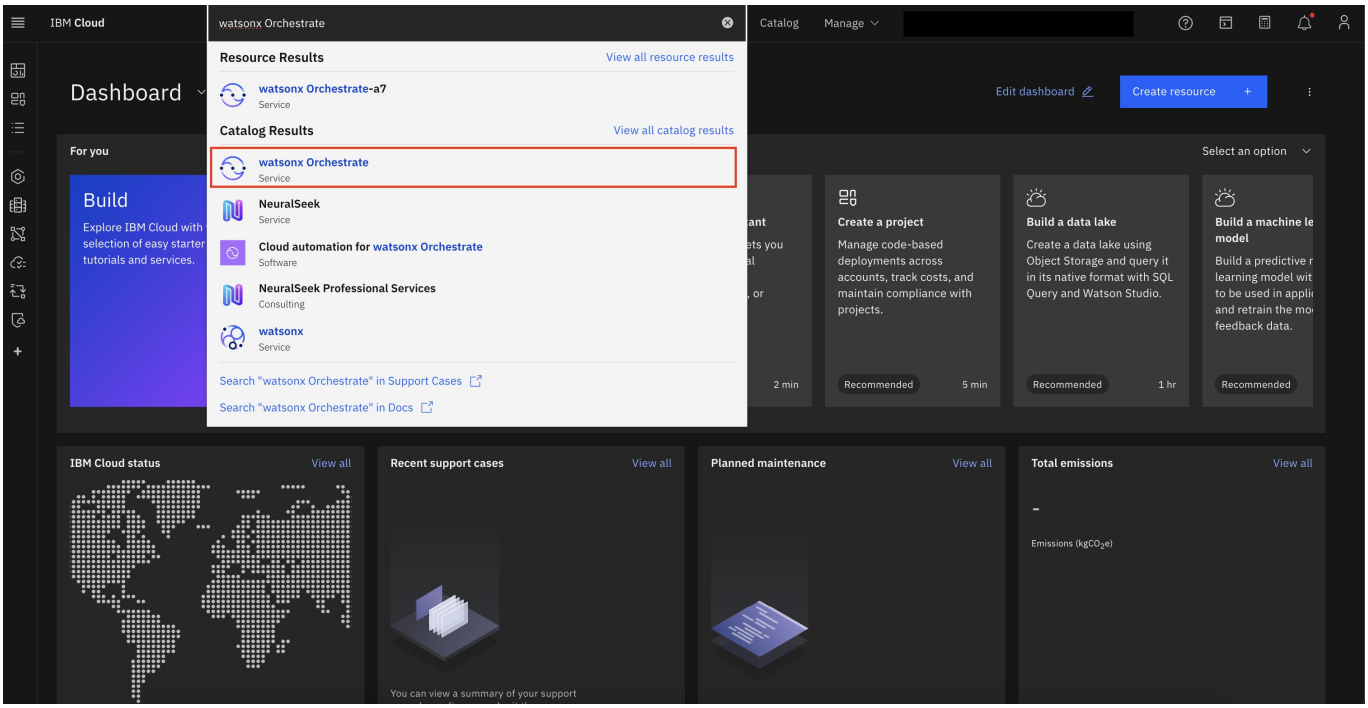

Escolha a **location** de sua instância e o **plano** que lhe atende melhor

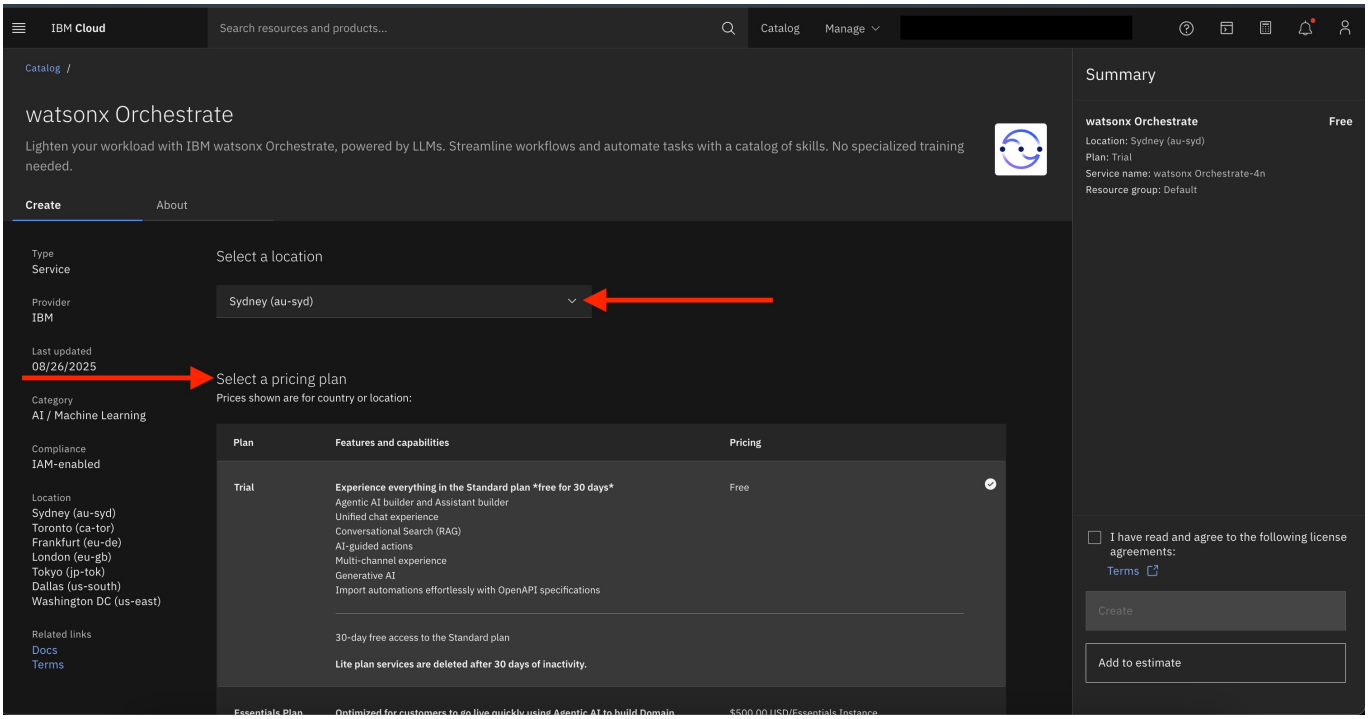

Por fim, digite o **nome do serviço**, opcionalmente **tags** e **tags de acionamento**, e selecione um **resource group**.

Aceite os termos da IBM Cloud ao lado direito da tela e clique em **Create**.

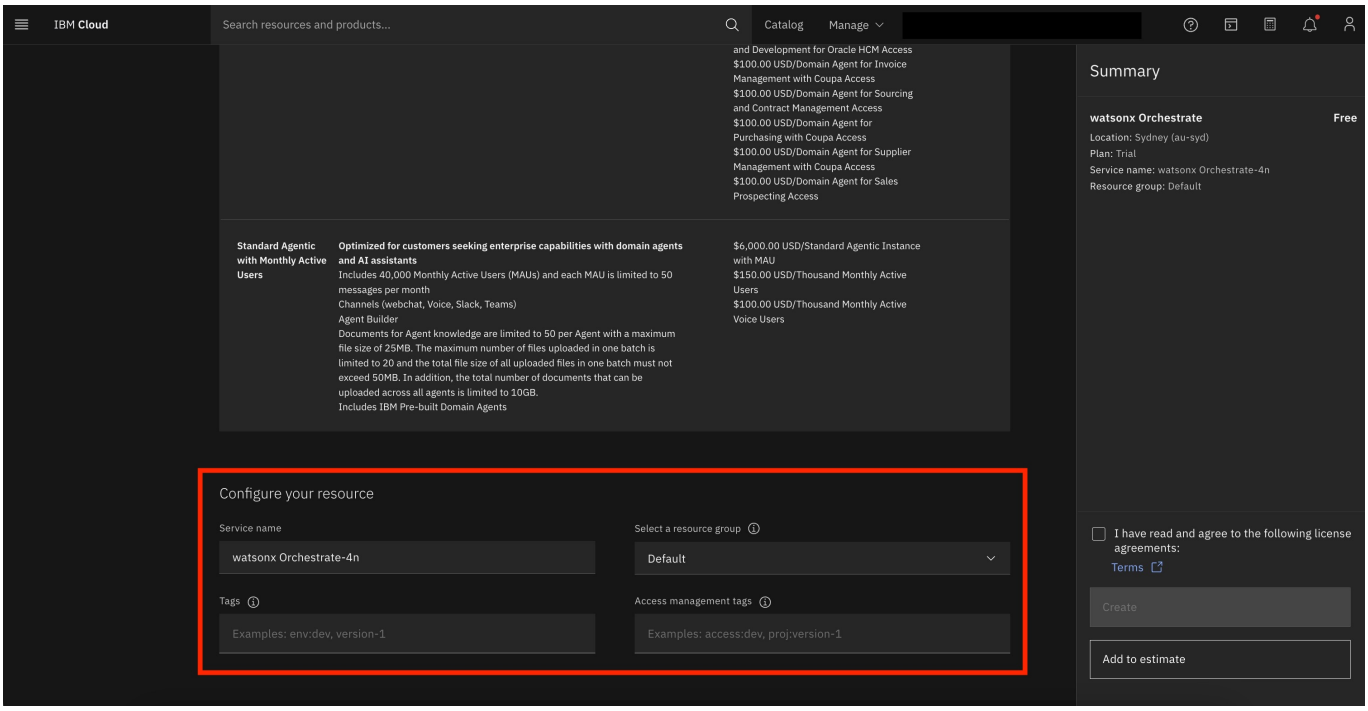

Com sua instância criada, clique em **Launch watsonx Orchestrate**.

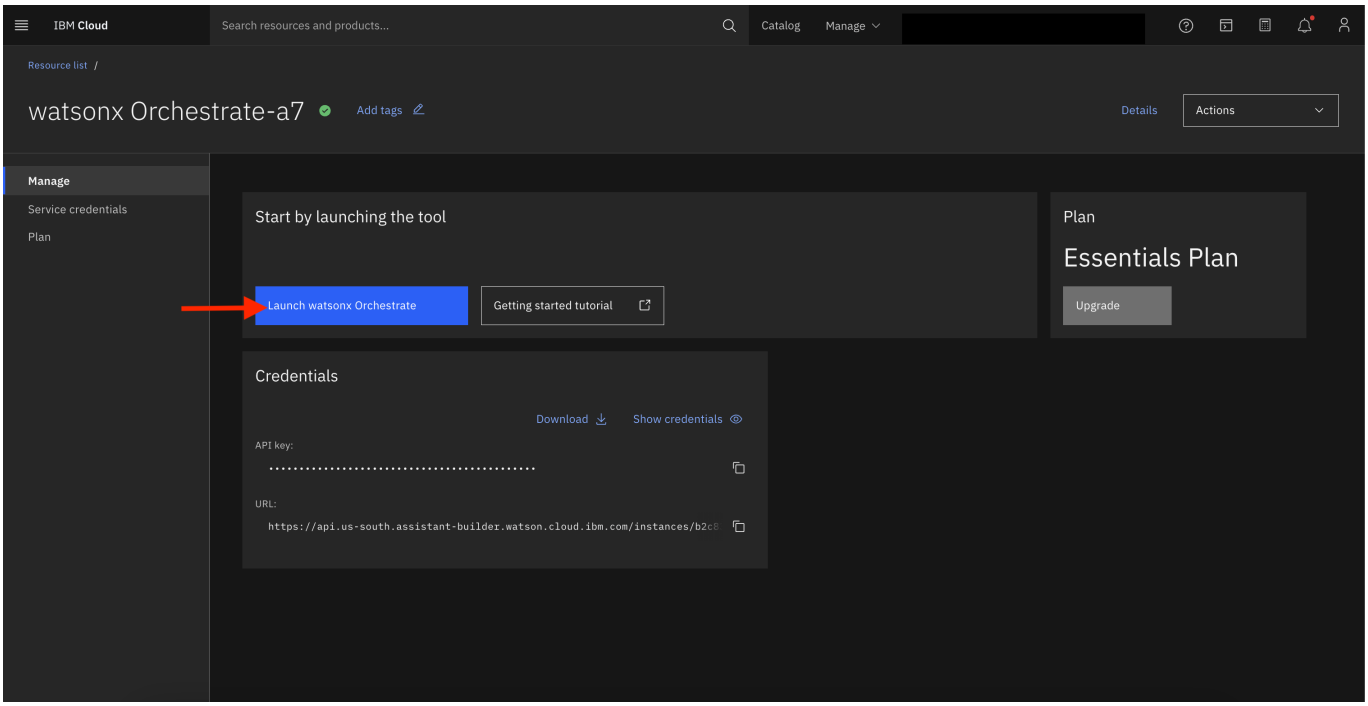

Para se comunicar com o Watsonx Orchestrate via API, você precisará obter duas credenciais essenciais:

- `IAM_API_KEY`
- `WXO_INSTANCE_ID`

Como obter as credenciais do watsonx Orchestrate

No ícone da sigla de seu nome e sobrenome ao lado direito da interface

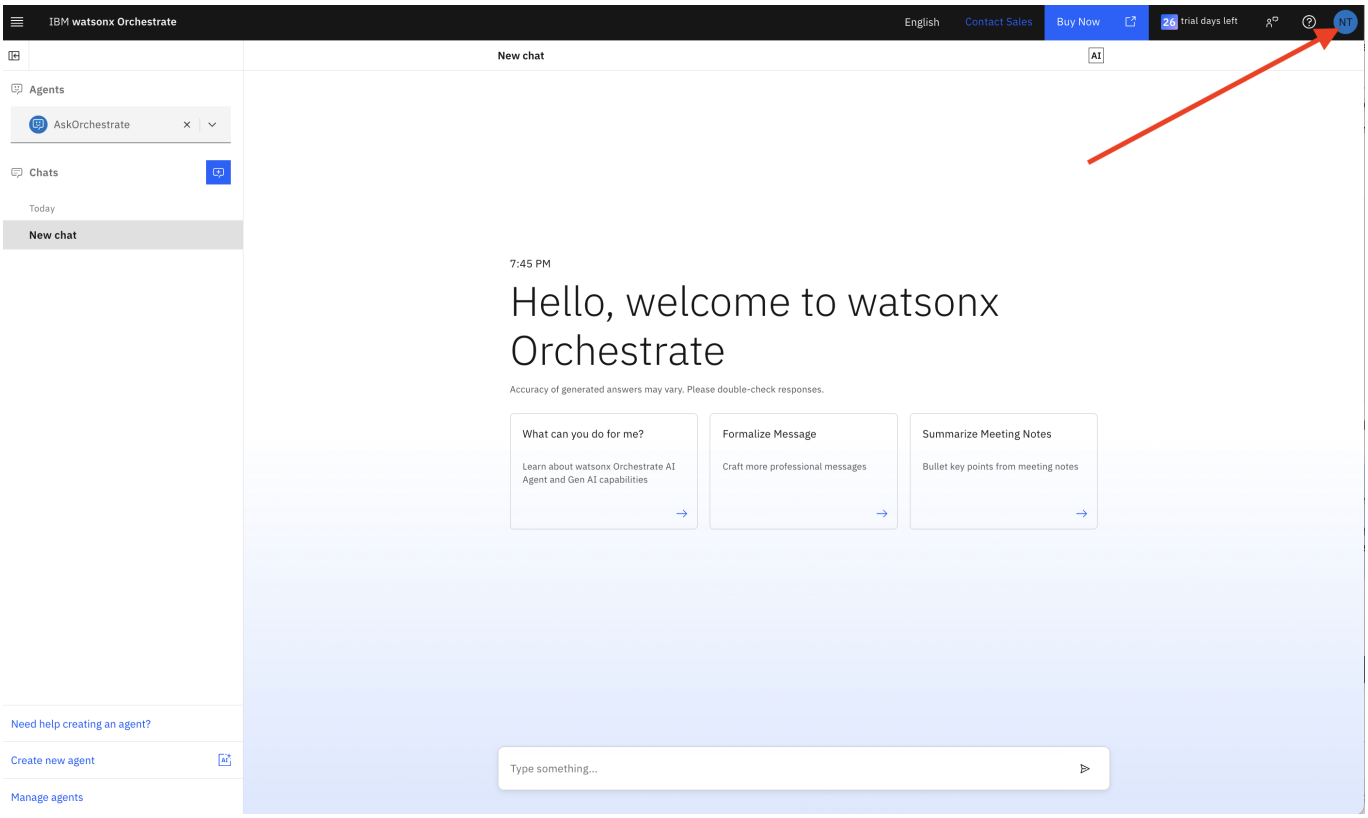

Clique em **Settings**.

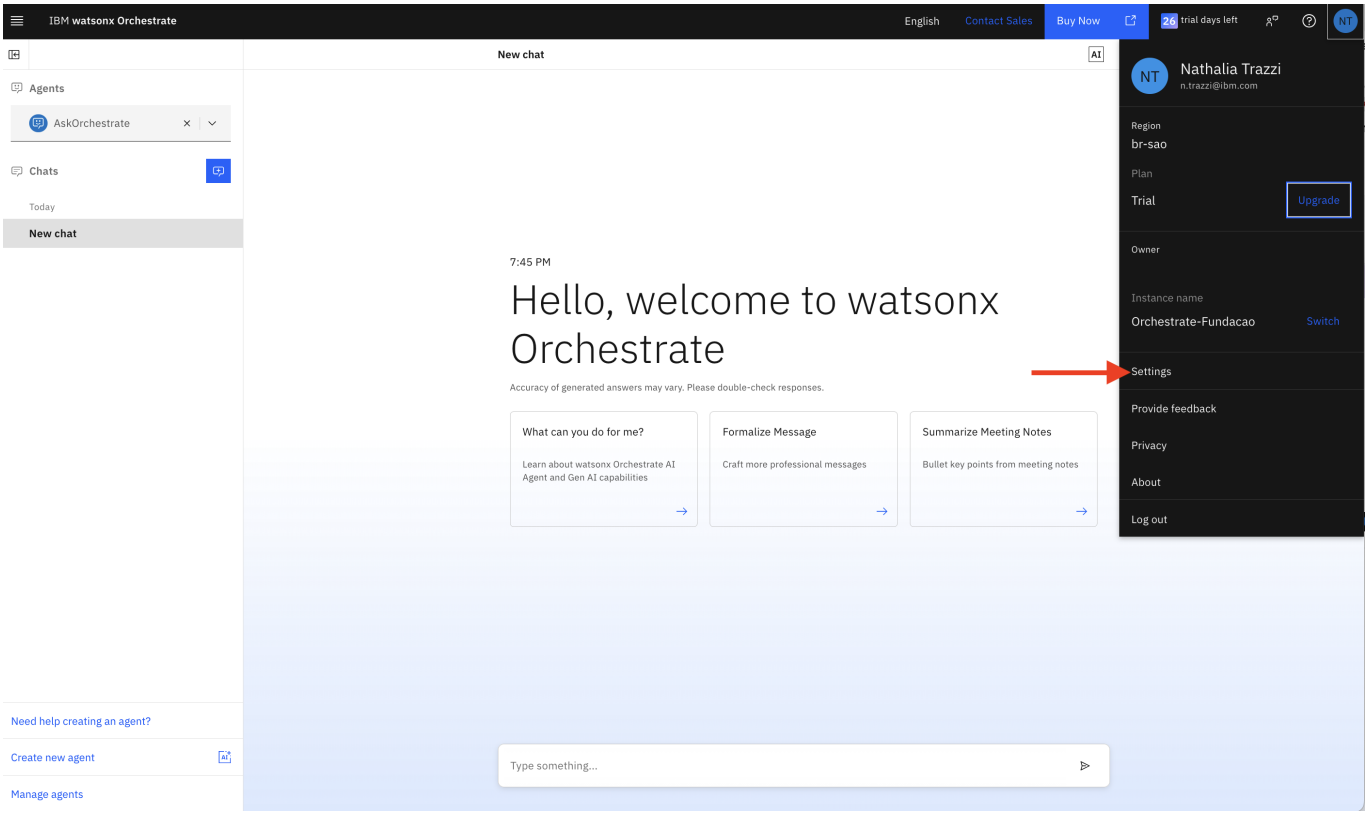

Na página de configuração e entre na aba **API details**

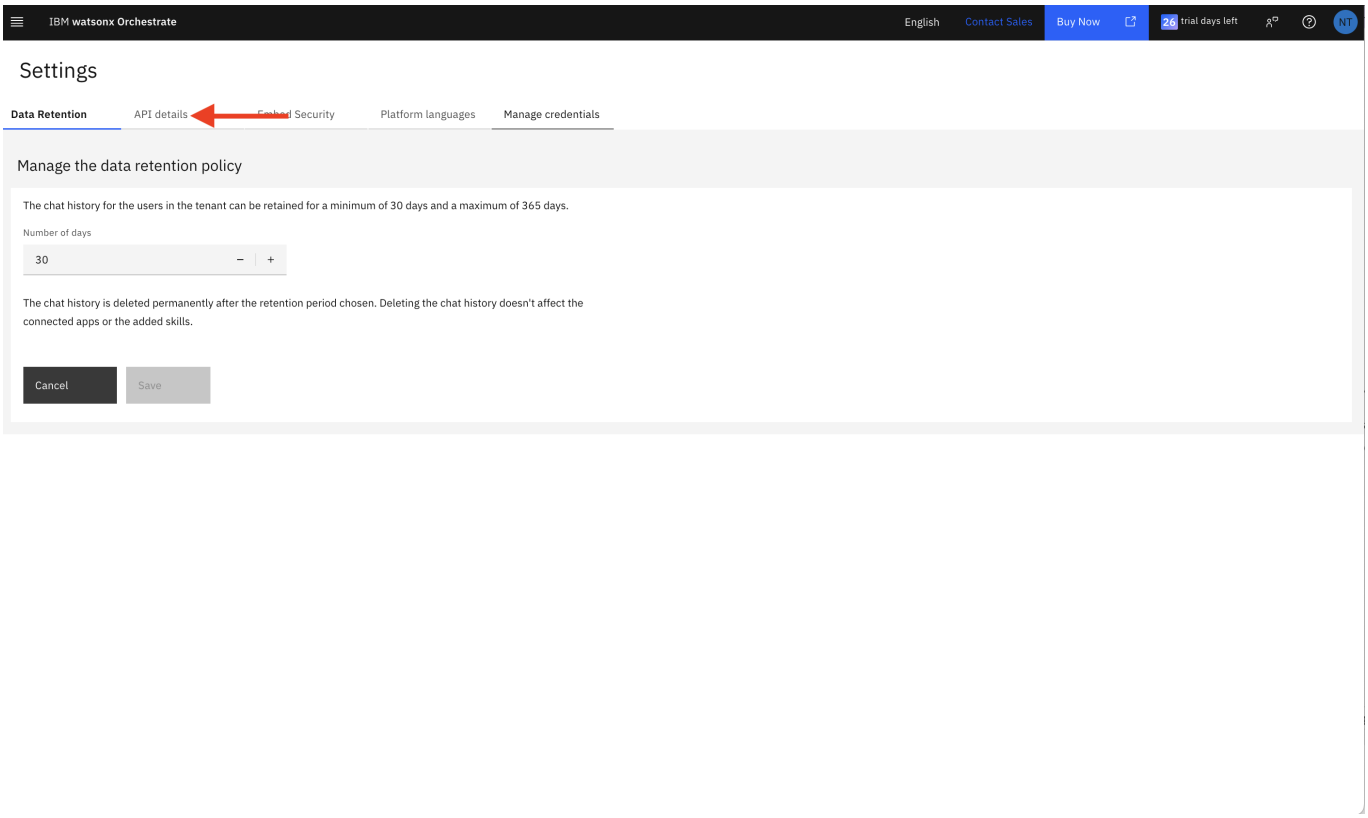

1. Copie o ID de sua instância

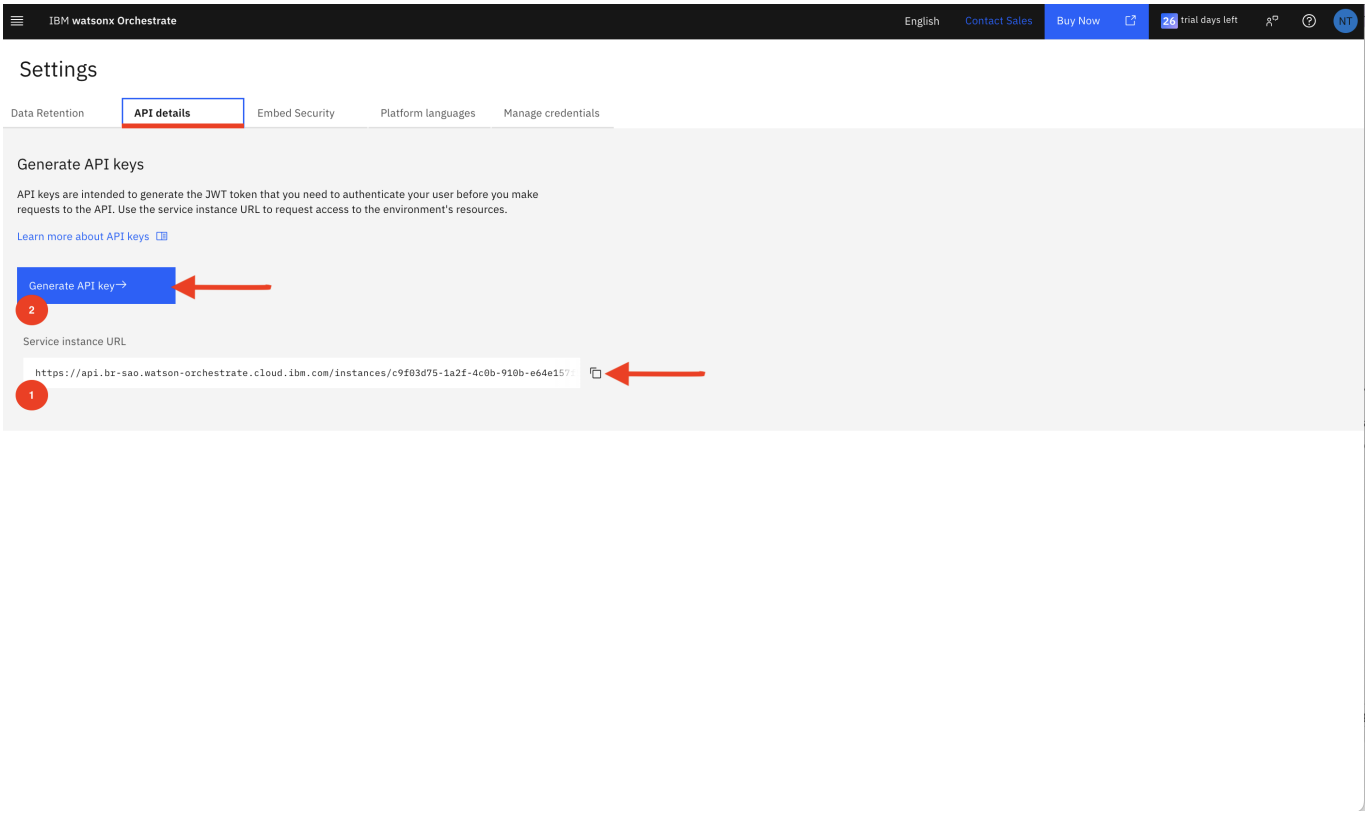

2. Em seguida, clique em `Generate API Key`

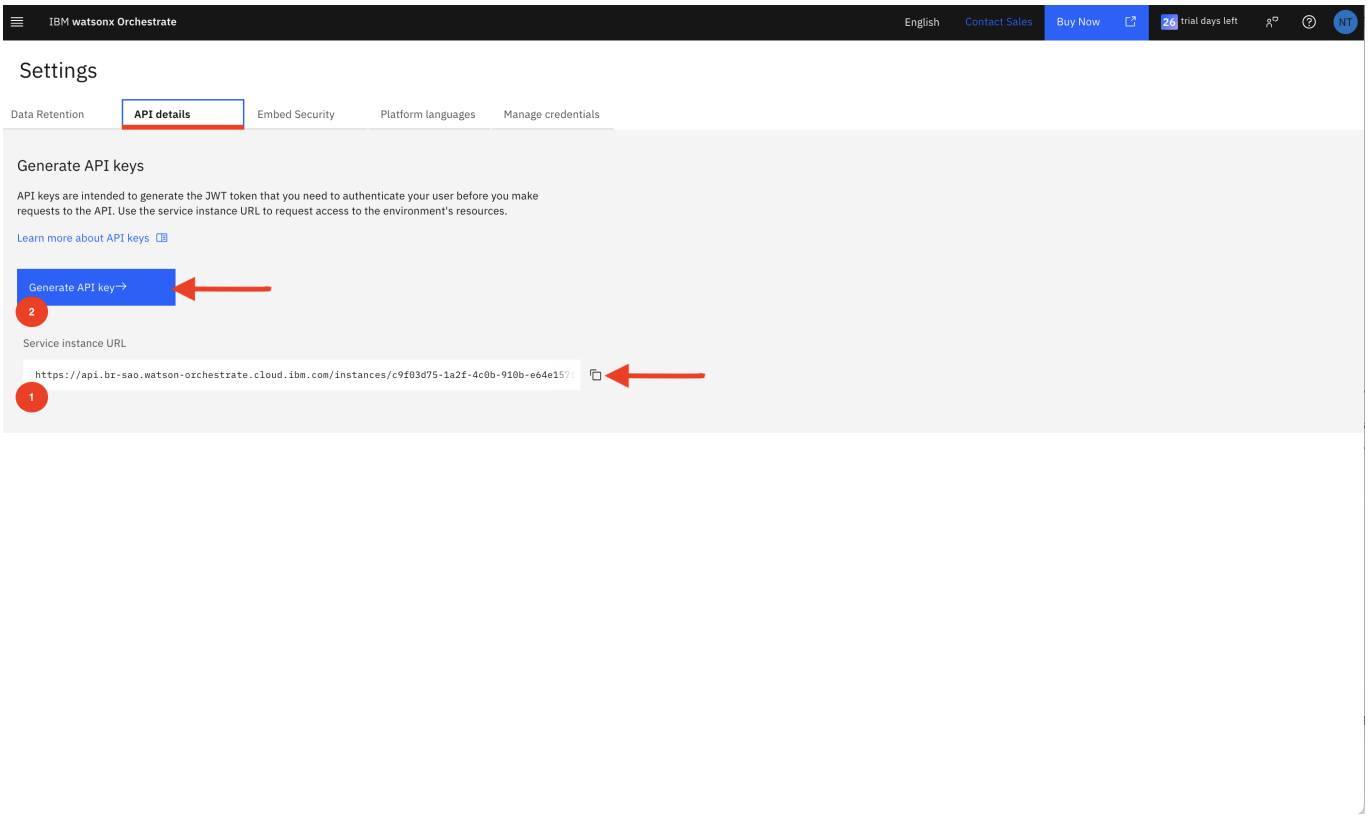

Na próxima página, clique em **Generate API key**.

Você será redirecionado para o catálogo onde você cria, visualiza e trabalha com chaves de API da IBM Cloud.

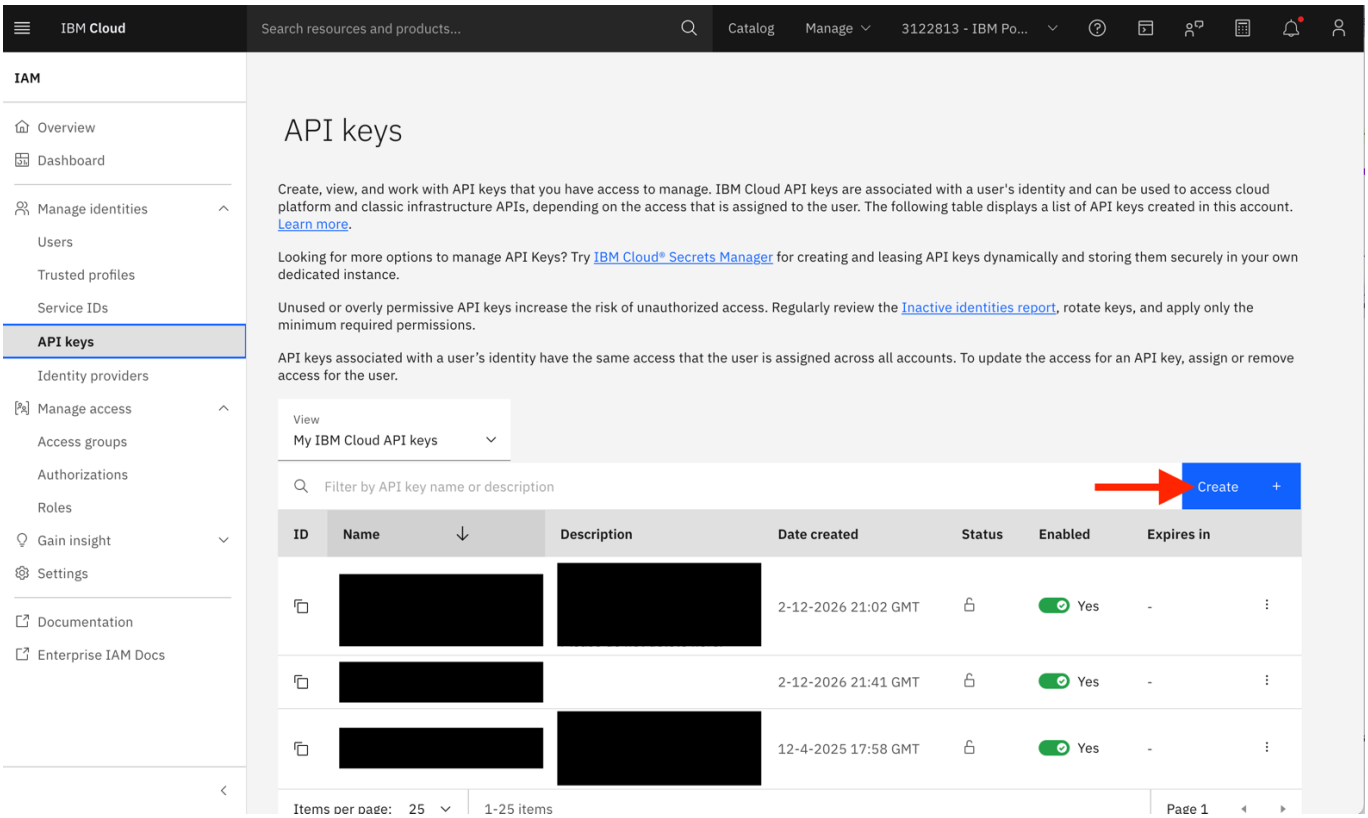

> **O que é uma API Key?**
>
> Uma API Key é um segredo que permite que usuários, aplicações ou serviços acessem a IBM Cloud de forma autenticada. Ela funciona como uma "senha técnica" usada em CLIs, automações,

> pipelines ou integrações.

Configuração da API Key

Name (Nome)

Dê um nome descritivo para a chave, como:

- `apikey-wxo`
- `local-development-key`

> **Dica**: Use nomes que indiquem o propósito, responsável ou ambiente.

Description (Opcional)

Aqui você pode adicionar uma descrição da sua chave, ajudando na identificação dela.

Lead Action (Ação em Caso de Vazamento)

Opção	Descrição
🔘 **Disable the leaked key** (recomendado)	A chave é automaticamente desativada. Boa opção para produção.
🔘 **Delete the leaked key**	A chave é deletada permanentemente.
🔘 **Nothing**	Nenhuma ação é tomada. Não recomendado.

API Key Expiration (Expiração)

Você pode escolher se a chave deve expirar automaticamente.

Opção	Descrição
🔘 **Set expiration**	Permite escolher uma data futura. -> Ideal para acessos temporários, integrações de curto prazo, etc. Quando expirar, a chave é automaticamente desabilitada.
🔘 **Sem expiração** (default)	A chave não expira.

Session Management (Gerenciamento de Sessão)

Define se esta chave pode ser usada para gerenciamento de sessões no IBM Cloud CLI.

Opção	Descrição
🔘 **Yes**	Permite que a chave seja usada para fazer login no CLI com `ibmcloud login --apikey`
🔘 **No**	A API Key não poderá ser usada para login em sessões CLI. Use quando desejar restringir a chave apenas para chamadas específicas de API.

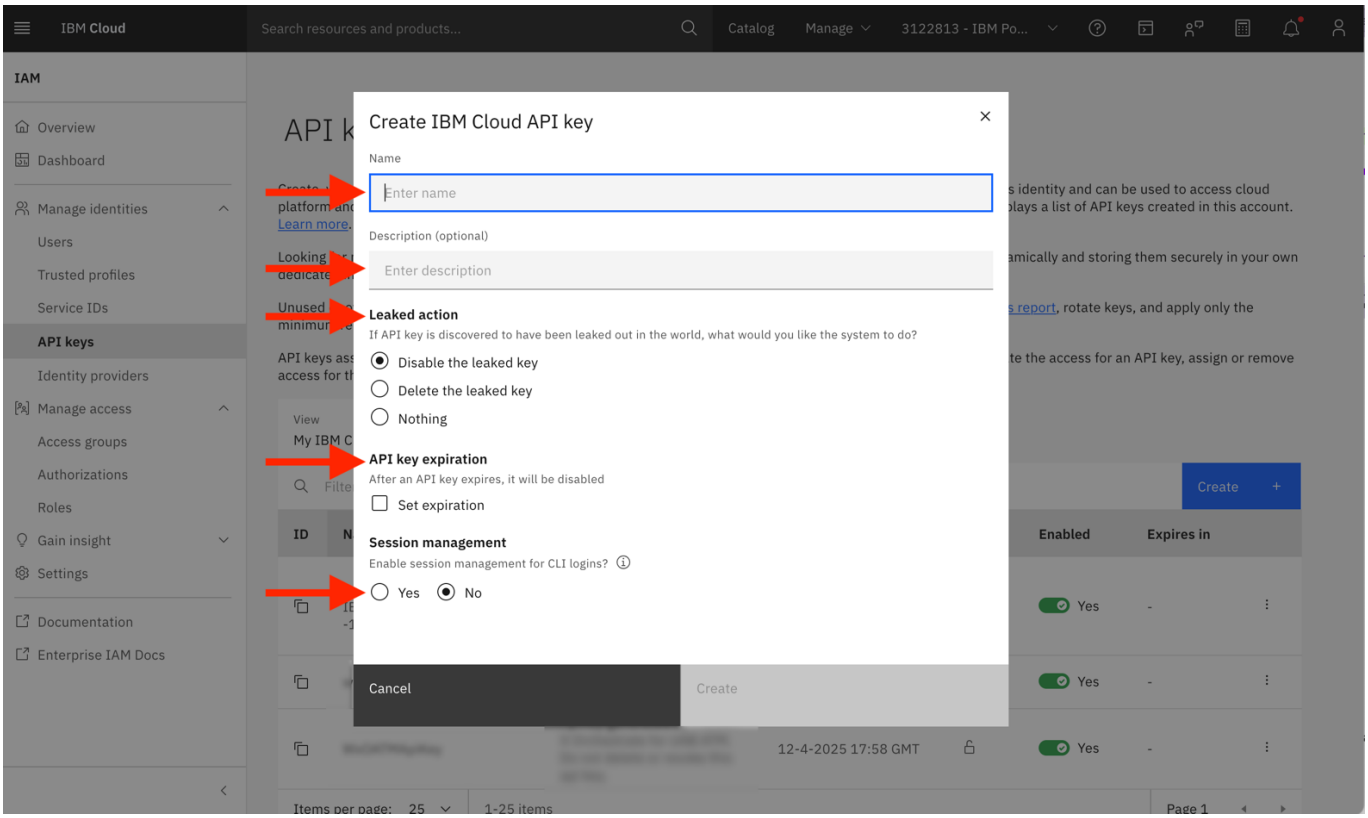

Após preencher tudo, clique em **Create**.

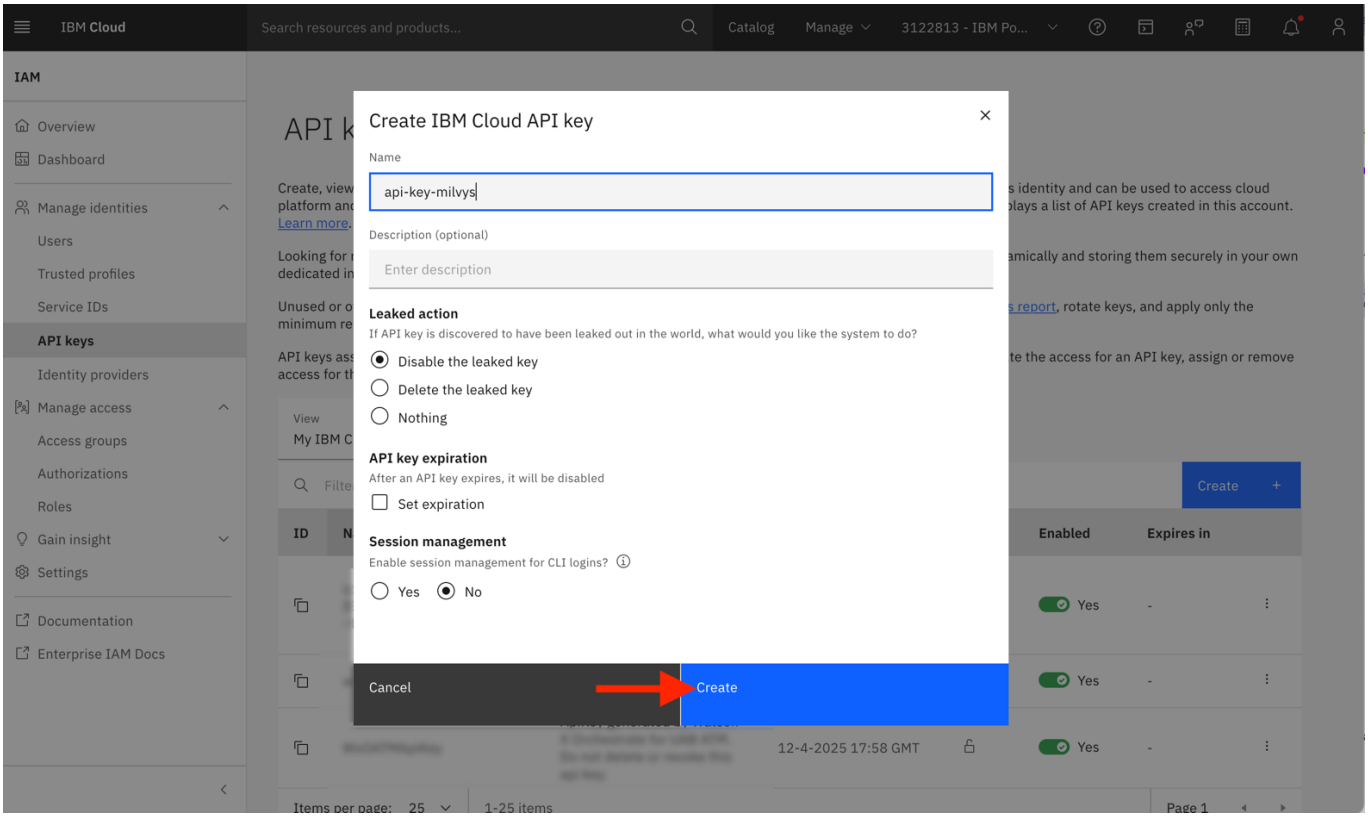

> **IMPORTANTE**: Aproveite esse momento para copiar ou fazer o download sua API Key. A chave ficará disponível por alguns segundos. Após esse período, não será mais possível visualizá-la novamente.

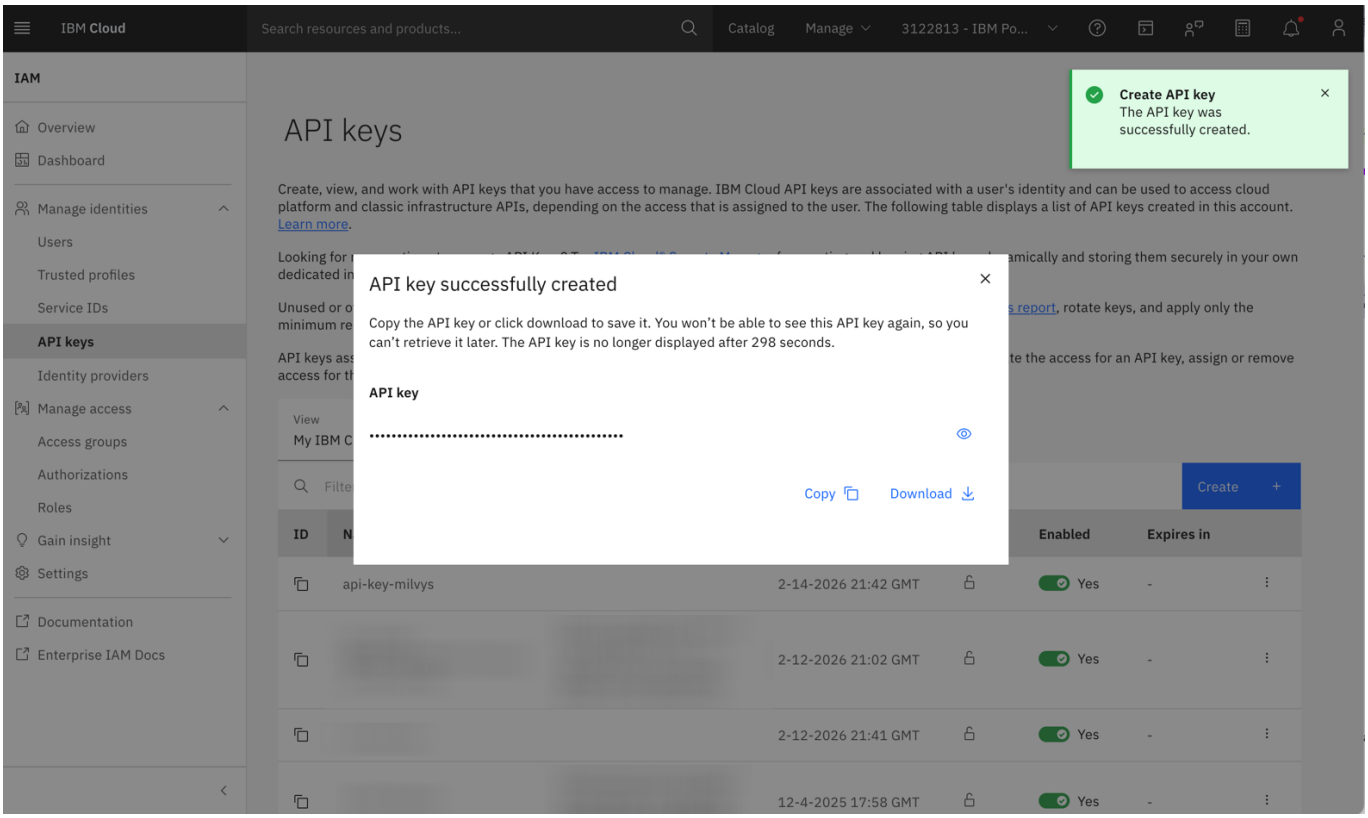

Após obter as credenciais, você já possui as duas informações necessárias para a execução da interação via backend com o chat do seu agent (watsonx Orchestrate).

1. **Navegue até o diretório do projeto**:

```
cd ./source/rest_api/
```

2. **Configure as variáveis de ambiente**:

   - Altere o nome do arquivo `.env_example` para `.env`
   - Preencha com suas credenciais:

```
IAM_API_KEY=sua-api-key-aqui
WXO_INSTANCE_ID=seu-instance-id-aqui
```

3. **Instale as dependências**:

```
pip install -r requirements.txt
```

4. **Execute o servidor**:

```
python app.py
```

Gerenciamento de Conversas (Thread ID)

> **Importante**: Para manter o contexto da conversa entre múltiplas mensagens:

- **Primeira mensagem**: Faça sua primeira chamada para `/get_response` ou `/stream_response` **sem fornecer** um `thread_id` (deixe vazio ou omita da requisição). A resposta incluirá um valor `thread_id`.
- **Mensagens subsequentes**: Para continuar a conversa no mesmo contexto, inclua o `thread_id` retornado como parâmetro em todas as requisições subsequentes.

Isso permite que o agente mantenha o contexto entre as mensagens.

`POST /get_response`

Envia uma mensagem para um agente e recebe uma resposta única.

Requisição (parâmetros de query):

```
POST /get_response?message=Hello&agent_id=your-agent-
id[&thread_id=optional-thread-id]
```

Parâmetros:

- `message` (obrigatório): A mensagem a ser enviada
- `agent_id` (obrigatório): ID do agente
- `thread_id` (opcional): ID da thread para continuar uma conversa

Observações:

- Para a primeira mensagem, **não inclua** `thread_id`
- Para mensagens seguintes, defina `thread_id` com o valor retornado na resposta anterior

Resposta:

```
{
  "response": "Agent response here",
  "thread_id": "thread-id-value"
}
```

`POST /stream_response`

Envia uma mensagem para um agente WxO e recebe a resposta de forma contínua (SSE).

Requisição (parâmetros de query):

```
POST /stream_response?message=Hello&agent_id=your-agent-id[&thread_id=optional-thread-id]
```

Parâmetros:

- `message` (obrigatório): A mensagem a ser enviada
- `agent_id` (obrigatório): ID do agente
- `thread_id` (opcional): ID da thread para continuar uma conversa

Observações:

- Para a primeira mensagem, **não inclua** `thread_id`
- Para mensagens seguintes, defina `thread_id` com o valor retornado na resposta anterior

Resposta:

```
Content-Type: text/event-stream

data: {"chunk": "Response", "thread_id": "thread-id-value"}

data: {"chunk": " chunk", "thread_id": "thread-id-value"}

data: {"chunk": " here", "thread_id": "thread-id-value"}
```

Cada bloco de dados do evento é enviado em tempo real conforme o agente processa a resposta.

Variáveis de Ambiente

Variável	Descrição
`IAM_API_KEY`	Chave de API do IBM Cloud IAM
`WXO_INSTANCE_ID`	ID da instância do Watsonx Orchestrate

Notas Importantes

> **Atenção**:
>
> - Certifique-se de que seu **ID do agente** seja válido
> - Sua **chave IAM** deve ter permissões suficientes para acessar a instância
> - O endpoint `/stream_response` usa **streaming (SSE)** para interagir com o agente watsonx Orchestrate processando respostas em tempo real

---

Agora você está pronto para integrar seu aplicativo com o IBM Watson Orchestrate.

Desenvolvido por Nathalia Trazzi